

分类号：TP391

学校代码：10697

密 级：公开

学 号：201620784



西北大学  
Northwest University

# 硕士学位论文

MASTER' S DISSERTATION

## 基于 ABM 和机器学习的土地利用变 化预测模型对比研究

学科名称：地图学与地理信息系统

作 者： 段 宁 指导老师：梁小英教授

西北大学学位评定委员会  
二〇一九年

分类号: TP391

密 级: 公开

学校代码: 10697

学 号: 201620784

# 基于 ABM 和机器学习的土地利用变化预测模 型对比研究

学科名称: 地图学与地理信息系统

作 者: 段宁 指导老师: 梁小英教授

西北大学学位评定委员会

二〇一九年

III

# **Simulation of farm households' land-use model based on ABM and Machine Learning**

A **thesis** submitted to  
Northwest University  
in partial fulfillment of the requirements  
for the degree of Master  
In Geography

By Duan Ning

Supervisor:

**January 2019**

## 西北大学学位论文知识产权声明书

本人完全了解西北大学关于收集、保存、使用学位论文的规定。学校有权保留并向国家有关部门或机构送交论文的复印件和电子版。本人允许论文被查阅和借阅。本人授权西北大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。同时授权中国科学技术信息研究所等机构将本学位论文收录到《中国学位论文全文数据库》或其它相关数据库。

保密论文待解密后适用本声明。

学位论文作者签名： 张方 指导教师签名： 梁小英

2019 年 6 月 9 日

2019 年 6 月 9 日

---

## 西北大学学位论文独创性声明

本人声明：所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，本论文不包含其他人已经发表或撰写过的研究成果，也不包含为获得西北大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名： 张方  
2019 年 6 月 9 日

---

## 摘要

近年来以土地利用与覆被变化为核心的复杂人地系统演变过程受到越来越多学者的关注,而基于微观土地利用主体的模型模拟是研究土地利用演变的主要方式之一,ABM 土地利用模型能够准确模拟 Agent 决策行为且易于建模分析,成为了当前研究土地利用变化的主流模型。

土地利用转化规则的设置是 ABM 土地利用模型的核心。由于土地利用转化的复杂性,加之巨量的地理数据,如何有效设定 ABM 模型转换规则已成为提高其解释力的主要方式之一。目前,国内外众多地理学者逐渐将目光转移到机器学习与深度学习方法之上。机器学习与深度学习在数据挖掘、特征提取和建模上优势明显。如何利用机器学习与深度学习算法的优势挖掘 ABM 模型土地利用转化规则构建耦合其与 ABM 模型的新模型就成为当前的研究热点问题之一。

高渠乡地处黄土高原,是我国典型的生态脆弱区。本文利用 PRA 和传统农户调查获取所需数据,结合机器学习算法、深度学习算法以及传统土地利用变化模型,构建新型模拟与预测土地利用变化模拟平台。该平台主要包括以下两方面内容:(1)以基于经验的 BDI 行为决策模型为基础,运用随机森林提取影响农户决策的变量,构建 RF-BDI 模型;(2)在 BDI 框架的指导下,运用随机森林算法选取最优特征向量,利用深度神经网络算法独立挖掘农户决策规则并构建土地利用变化模拟模型。通过分析该平台模拟结果可以得出以下结论:

(1) 随机森林算法与 BDI 模型结合可以有效模拟农户有限理性决策行为及其变化机理。以陕西省米脂县高渠乡为例,对比分析 RF-BDI 模型与传统 BDI 模型模拟结果,结果显示 RF-BDI 模型对传统 BDI 模型决策行为进行修正后,在没有明显增大计算量的基础上模拟精度提高了 14%。

(2) 相比 BDI 决策模型与 RF 模型,RF-BDI 模型的转化规则的设置更为合理。传统 BDI 模型是人为基于经验确定农户的决策规则,此规则设定较为简单,且过于刚性。随机森林算法虽可以“挖掘”农户土地利用行为规则,但挖掘规则过于理性,无法反应农户的随机种植行为。RF-BDI 模型通过将随机森林挖掘规则与基于经验的规则进行相互印证,可以有效消除农户随机种植行为带来的误差,提高模型模拟精度。

(3) 虽然 RF-BDI 模型可以较好的模拟农户种植行为,但仍有约为 20%的误差,

---

深度学习相较于机器学习具备更好的挖掘能力与模拟能力，本文基于 Keras 深度学习模块，设计与调整网络结构，以陕西省米脂县高渠乡为数据源，构建深度神经网络模型，对比深度神经网络模型与 RF-BDI 模型模拟情况。在未设置经验规则的前提下，深度神经网络模型独立提取农户有限理性决策规则，模拟与预测高渠乡土地利用变化并与实际土地利用变化进行对比，其模型精度为 85.2%，相较于 RF-BDI 模型，深度神经网络模型模拟精度提高约为 5%。该模型可以有效模拟农户随机种植行为，并预测其未来种植倾向，为刻画高渠乡未来土地利用变化情形及其驱动机制提供了一个新方式。

（4）深度神经网络模型对农户土地利用行为有较强的刻画能力，且对农户基于自身意愿的随机种植行为有强拟合能力。但深度神经网络模型仅仅能够显示农户最终种植结果，其中间过程参数过于复杂不利于分析微观层面人地系统演变的驱动机理，而 RF-BDI 模型可以直观反映各个影响因素在人地系统演变过程中的相对重要性，综合深度神经网络模型的模拟能力以及 RF-BDI 模拟在机理解释上的优点是下一步需要进行的工作。

**关键词：**土地利用行为模拟，农户决策，随机森林，深度神经网络，Keras

---

## ABSTRACT

In recent years, more and more scholars have paid attention to the evolution process of complex man-land system with land use and cover change as the core. Modeling based on Micro-land use subject is the main way to study land use evolution. ABM land use model can accurately simulate agent decision-making behavior and is easy to model and analyze. It has become the mainstream model of current land use change research.

The establishment of land use conversion rules is the core of ABM land use model. Due to the complexity of land use transformation and the huge amount of geographic data, how to effectively set the rules of ABM model transformation has become one of the main ways to improve its explanatory power. At present, many geographers at home and abroad gradually turn their attention to machine learning and deep learning methods. Machine learning and deep learning have obvious advantages in data mining, feature extraction and modeling. How to utilize the advantages of machine learning and deep learning algorithms to mine the rules of land use transformation of ABM model and build a new model coupling it with ABM model has become one of the current research hotspots.

Gaoqu Township, located on the Loess Plateau, is a typical ecologically fragile area in China. In this paper, PRA and traditional household surveys are used to obtain the required data, and a new simulation platform for simulating and predicting land use change is constructed by combining machine learning algorithm, deep learning algorithm and traditional land use change model. The platform mainly includes the following two aspects: (1) Based on the experience-based BDI behavior decision-making model, the RF-BDI model is constructed by using random forest to extract variables affecting farmers' decision-making; (2) Under the guidance of BDI framework, the stochastic forest algorithm is used to select the optimal eigenvector, and the deep neural network algorithm is used to independently mine farmers' decision-making rules and construct land use change. Simulate the model. By analyzing the simulation results of the platform, the following conclusions can be drawn:

(1) The combination of random forest algorithm and BDI model can effectively represent the limited rational decision-making behavior of farmers. In order to explore the

---

effectiveness of random forest algorithm for land use change simulation, this paper compares the RF-BDI model with the traditional BDI model in Gaoqu Township, Mizhi County, Shaanxi Province. The results show that the RF-BDI model is a traditional BDI model. After the decision behavior was revised, the simulation accuracy was improved by 14% without significantly increasing the amount of calculation.

(2) Whether the setting of the conversion rule is appropriate directly determines the simulation result. The traditional BDI model is a human-based decision-making rule based on experience. This rule is simpler and more rigid. The random forest algorithm can mine farmers' land use behavior rules through machine learning based on big data. Farmers have random planting behaviors when planting, random forest algorithm design is relatively simple, mining rules are too rational, and random forest mining rules and experience-based rules are mutually confirmed, which can effectively eliminate the errors caused by random planting behaviors of farmers and improve model simulation Precision.

(3) Although RF-BDI model can better simulate farmer's planting behavior, it still has about 20% error. Deep learning has better mining and simulation ability than machine learning. Based on Keras deep learning module, this paper designs and adjusts network structure. Taking Gaoqu Township of Mizhi County in Shaanxi Province as data source, constructs a deep neural network model, and compares the deep neural network model with RF - BDI model simulation. On the premise of no empirical rules, the depth neural network model independently extracts farmers'bounded rational decision rules, simulates and predicts land use change in Gaoqu Township and compares it with the actual land use change. The accuracy of the model is 85.2%. Compared with the RF-BDI model, the simulation accuracy of the depth neural network model is improved by about 5%. The model can effectively simulate the random planting behavior of farmers and predict their future planting tendency. It provides a new way to describe the future land use change and its driving mechanism in Gaoqu Township.

(4) The deep neural network model has a strong ability to describe the land use behavior of farmers, and has a strong ability to fit the random planting behavior of farmers based on their own wishes. However, the deep neural network model can only show the final planting results of farmers, among which the intermediate process parameters are too



---

complex to analyze the driving mechanism of human-land system evolution at the micro level. The RF-BDI model can directly reflect the relative importance of various factors in the process of human-land system evolution, and synthesize the simulation ability of the deep neural network model and the interpretation of the RF-BDI simulation in machine. The advantage is that the next step needs to be done.

**Keywords:** Land use behavior simulation, land use decision-making of farmer household, Random forest, deep neural network, Keras

---

# 目录

摘要.....	IX
ABSTRACT.....	XI
第一章 绪论.....	1
1.1 选题背景及意义.....	1
1.2 国内外研究进展.....	2
1.2.1 传统土地利用模拟模型.....	2
(1)CA 模型.....	2
(2)ABM 模型.....	2
1.2.2 机器学习算法.....	3
1.2.3 机器学习与传统土地利用模型耦合.....	4
1.2.4 基于深度学习的土地利用模型.....	4
1.3 主要研究内容与技术路线图.....	5
1.3.1 主要研究内容.....	5
(1) BDI 决策框架的构建.....	6
(2) RF-BDI 决策框架的构建.....	6
(3) DNN 决策框架的构建.....	6
(4) RF-BDI 模型与 DNN 模型对比研究.....	6
1.3.2 技术路线图.....	6
1.4 研究创新点.....	7
1.4.1 随机森林与 BDI 决策模型的耦合.....	7
1.4.2 基于深度学习的土地利用变化模型.....	8
第二章 研究区概况与数据处理.....	9
2.1 研究区概况.....	9
2.2 数据来源.....	10
2.3 数据处理.....	11
2.3.1 RF-BDI 模型数据处理.....	11
2.3.2 DNN 模型数据处理.....	11
第三章 RF-BDI 模型的构建与模拟.....	13
3.1 相关概念说明.....	14
3.1.1 Agent.....	14
3.1.2 BDI 行为理论.....	14
3.1.3 随机森林.....	14

3.2 研究方法	15
3.2.1 基于 BDI 决策框架的农户土地利用决策模型构建	15
(1) 信念构建	15
(2) 愿望构建	16
(3) 意图构建	16
3.2.2 基于随机森林的 RF-BDI 模型的构建	17
3.3 结果分析	21
3.3.1 BDI 决策模型结果分析	21
3.3.2 RF-BDI 模型结果分析	22
3.4 RF-BDI 模型程序实现	25
3.5 本章小结	26
第四章 基于 DNN 的农户土地利用行为模型构建	27
4.1 相关概念	27
4.1.1 相关名词解释	27
(1) 深度神经网络	27
(2) 激活函数	28
(3) 优化函数	28
(4) 梯度下降	28
(5) 正则化	29
4.1.2 深度神经网络算法简介	29
4.1.3 Keras 开发模块简介	30
4.2 基于深度学习的土地利用模型构建	30
4.3 结果分析	33
4.3.1 深度神经网络模型结果分析	33
4.3.2 RF-BDI 模型与 DNN 模型对比分析	37
4.4 本章小结	38
第五章 结论与讨论	40
5.1 结论	40
5.2 讨论	40
参考文献	42
致谢	49
攻读硕士学位期间取得的科研成果	49

---

# 第一章 绪论

## 1.1 选题背景及意义

以人地关系为核心的全球可持续发展问题受到国内外学者的关注<sup>[1-9]</sup>。其演变过程是以自然与人文因素互相影响的复杂演变过程,而构建微观主体决策行为模型是研究土地利用变化的主要方式之一,其有助于揭示土地利用变化机制与机理、辅助城乡规划与相关政策制定<sup>[8,10-17]</sup>。元胞自动机 CA 模型和 ABM 模型这两种建模方法因其能够刻画 Agent 所处环境且易于建模受到国内外学者的广泛使用<sup>[18-20]</sup>。CA 模型通过改变其元胞状态能够有效反映微观土地系统变化过程的复杂特征,但 CA 模型模拟结果主要取决于自身及邻域状态,影响因素较为单一,不能有效表达土地利用变化的微观主体的行为规则及其变化机制<sup>[21-25]</sup>。恰恰相反,ABM 模型能够详细刻画微观主体的决策行为,可以弥补 CA 模型在表达主体决策行为时的不足<sup>[25-27]</sup>。ABM 模型是由 N 个相互交融的智能体构成的,每个智能体具有独立行为且智能体之间可以互相影响<sup>[28-29]</sup>。

土地利用转化规则的设置是 ABM 土地利用变化模型的核心<sup>[28,30]</sup>。但目前存在规则设置较为简单,且较为刚硬。如何有效设置土地利用转化规则就成为提高 ABM 模型的关键问题<sup>[31]</sup>。机器学习作为从数据中学习规律的一门方法,已经显示出在地理学研究中强大潜力。目前,众多国内外地理学者开始尝试将机器学习方法用于地理学研究中,以 CLUE-S 模型、CA-Markov 模型、GeoSOS 模型为代表,通过耦合机器学习方法与土地利用变化模型取得了不错的模拟效果,但仍有相应的进步空间<sup>[32-35]</sup>。与机器学习算法相比,深度学习算法可以从相同数据集中挖掘更深层次的客观规律,且比机器学习具备更好的泛化能力<sup>[36-37]</sup>。目前深度学习在行人检测、图像分类、自然语言识别、语义识别等领域表现出优越的能力<sup>[38-40]</sup>,但深度学习在土地利用变化模型方面研究还不多见。如何结合深度学习的方式和手段,构建深度学习的模拟平台,对微观主体行土地利用行为进行更为高效的模拟将是今后研究的主要方向之一<sup>[41]</sup>。

---

## 1.2 国内外研究进展

### 1.2.1 传统土地利用模拟模型

#### (1)CA 模型

CA 模型是由 Wolfram 提出的空间、时间离散且通过局部规则获得全局涌现特征的动力学模型,常被用于地理时空演变以及过程的建模和模拟<sup>[42]</sup>。主要包括元胞、邻域、空间和转化规则 4 个组成部分<sup>[43-44]</sup>。在传统 CA 模型中,不同元胞状态代表不同土地利用类型,通过每个元胞的邻域状态以及转化规则确定元胞判定该元胞转化为不同类型元胞的概率。CA 模型充分体现了自组织系统中微观主体行为在宏观土地利用变化中的涌现<sup>[45-46]</sup>。该模型具有以下几点优势<sup>[42,47-48]</sup>: (1)能够通过改变其元胞状态模拟出复杂的人地系统演变情形; (2)能够分析复杂土地系统的演变过程; (3)能与 GIS 数据和遥感数据完美对接,能够有效提高 GIS 空间分析能力及其时空动态建模能力。目前,国内外关于 CA 模型的研究已经相当成熟。王帅等通过建筑用地指数提取影像作为 CA 模型的原始数据集,通过阈值分割、腐蚀、连通性检测等处理来提取城市建成区的边界<sup>[49]</sup>。黄焕春等以 1998-2014 年天津市滨海新区城市边界为训练数据集,耦合传统 CA 模型与灰色预测算法,模拟预测滨海新区城市演化过程<sup>[50]</sup>。

虽然 CA 模型能够有效模拟 Agent 的状态,但其元胞位置无法改变,只能对其元胞状态作出相应改变<sup>[51]</sup>。因此,CA 模型较少考虑人地系统演变过程中的社会经济因素,主要以自然条件因素为主<sup>[52-53]</sup>。

#### (2)ABM 模型

复杂土地系统的演变是由微观主体之间、主体与其所处环境之间相互调节而产生的结果<sup>[54]</sup>。在 ABM 模型中,不同微观主体之间及其与所处环境互相影响,微观主体调整自身状态以及作出相应决策行为来适应环境。ABM 模型不仅能够模拟主体之间及其与所处自然环境相互作用,而且能够刻画复杂土地系统演变过程中影响主体决策的因素以及决策行为规则<sup>[55]</sup>。不同于 CA 模型,ABM 模型能够较好刻画土地利用变化过程中的人地关系,在研究人地系统演变过程中受到国内外学者的关注。

ABM 模型的核心是微观主体及其转换规则。不同类型 Agent 具有不同的状态、愿望、意向等属性,从而产生不同的决策行为,导致了不同微观主体之间相互影响并反馈于环境,最终“涌现”于宏观土地利用变化中<sup>[56-58]</sup>。而 BDI(Belief-Desire-Intention)

行为理论作为一种描述微观 Agent 在信念、愿望和意图等方面思维状态的认知理论<sup>[59]</sup>, 不仅能够详细刻画微观主体的决策过程, 而且具有便于设计、灵活等特性, 在模拟微观主体决策方面具有一定的心理学基础<sup>[60]</sup>。目前, 国内已有不少关于 BDI 模型在土地利用变化方面的研究。陈海等以 BDI 行为理论为核心, 构建微观农户土地利用决策行为模型, 实践证明 BDI 行为理论适宜微观主体土地利用变化决策行为的分析与研究<sup>[61]</sup>。宋世雄等构建基于 BDI 行为理论的 CBDI 模型以分析同类微观主体之间的相互影响, 通过对比同一类型微观主体的耕种面积的大小来表征农户对于耕种的意愿, 分析农户主体的土地利用行为及其影响机制<sup>[62]</sup>; 王燕妮等则基于传统 BDI 决策框架, 结合有限理性行为理论并以能力与资源系数调整微观主体决策行为构建有限理性能力与资源 BDI (CR-BDI) 决策模型, 模拟了农户视角下的土地利用演变情形<sup>[63]</sup>。

虽然 ABM 土地利用模型在模拟人地系统演变时可以较好的表达自然与人文因素, 但是其转换规则设置没有固定的算法支撑, 通常是由研究者基于自身经验确定, 设置较为刚性, 因此使用 ABM 模型模拟农户决策行为通常需要一种独立算法或模型挖掘转换规则。

### 1.2.2 机器学习算法

随着大数据时代的到来以及计算机硬件的发展, 机器学习算法受到众多学者的关注, 已经广泛应用于各个行业之中。机器学习算法通常包括学习、模拟人类的思考过程、对具有缺失信息的数据集进行预测以及分类的能力、基于浅层数据集发现客观规律的能力等特点<sup>[64-65]</sup>。

常见的机器学习算法包括: 决策树算法、SVM 算法、PCA 算法、随机森林算法等<sup>[66-67]</sup>, 随机森林算法因其高效分类地理大数据, 以及不需要特征选择且训练过程中能够监测不同影响因素之间的相互作用, 在训练完成后能够直观表达变量重要性等优点广泛应用于地理学预测中<sup>[68]</sup>。

随着对深度学习研究深入, 对比机器学习算法可以得出: 在本质上这些方法类似, 根据待处理数据的本质特征对其进行分类。然而, 深度学习方法具有更为优秀的分类能力, 它能从较少样本量的数据集中有效准确地提取数据的本质特征。深度学习算法可以利用一种深层非线性算法将原始数据集的特征进行分类表示, 实现将数据低层特征抽象成易于分类的高层特征。随着逐渐完善深度学习算法以及各种深度学习模型的提出, 使得深度学习更有利于挖掘数据的局部和全局特征, 且这些特征更具代表性,

---

这在理论上为基于深度学习的土地利用变化模拟带来了一个全新的研究思路。

### 1.2.3 机器学习与传统土地利用模型耦合

将 CA 模型用于模拟土地系统演变过程，需要解决确定转化规则与相关参数、整合自然和人文影响因素等问题。因此国内外学者主张将机器学习方法与 CA 模型耦合，利用决策树、随机森林算法、主成分分析、极限学习机、支持向量机等机器学习算法挖掘不同元胞之间的转化规则<sup>[69-70]</sup>。随机森林算法获取 CA 模型的转换规则与参数较为简单，得到了国内外学者的认可。随机森林 CA 模型只需通过随机森林算法拟合原始数据集，便可以自动获取 CA 模型的转换规则，张大川等基于随机森林算法挖掘不同元胞之间的转换规则，计算各个影响因素的贡献度，模拟并预测东莞市土地利用动态变化情形<sup>[71]</sup>。支持向量机算法能够简单并有效解决非线性问题，杨建新等以湖北省鄂州市遥感影像数据为数据源，通过最小二乘支持向量机算法获取 CA 模型转换规则，模拟并预测了湖北省鄂州市的人地系统时空动态演变<sup>[72]</sup>。马晶等分别利用 Logistic-CA、ANN-CA 和 DT-CA 这 3 种模型对长春市主城区 1995—2005 年、2005—2015 年的城市扩展情况进行了模拟<sup>[73]</sup>。

构建 ABM 土地利用演变模型时，如何确定微观主体的决策规则以及模型参数是 ABM 模型的核心问题<sup>[74]</sup>。目前 ABM 模型与机器学习方法耦合的研究还不多见，陈宝芬（2017）等以地理加权回归 CA 和 ABM 模型相耦合的城市扩张模型，模拟了福州市 2000-2015 年城市用地扩张变化情形以 1998-2014 年天津市滨海新区城市边界<sup>[75]</sup>。将机器学习引入 ABM 模型，对 ABM 模型转换规则的智能获取与纠正以及提高模型模拟精度都会有明显帮助。将机器学习算法与 ABM 模型耦合可以明显提高模型精度，但在机器学习算法选择时，需要选择能够较好解释其转换机理的算法。

### 1.2.4 基于深度学习的土地利用模型

地理大数据具有高维、存在相应的缺失值、以及数据测量困难且数据之间的关系呈现非线性等特点，利用传统的统计学方法分析地理大数据十分困难，不能刻画其内在的客观规律<sup>[76]</sup>。因此，分析地理大数据需要一种可以分离其之间的非线性关系的方法，并且对数据的缺失值具备一定的鲁棒性<sup>[77]</sup>。除此之外，这些方法最好具备简单操作、易于理解、以及对其分析结果提供相应的合理解释等特点，目前仅使用机器学习算法挖掘地理大数据之间的内在联系已经遇到了相应的瓶颈，一些学者通过组合多种

机器学习算法试图解决此中窘境，但效果不甚理想，故现在越来越多的学者将目光聚焦于深度学习算法<sup>[78]</sup>。近年来，深度学习作为模拟与分类的热门方法，已经在图像分类、行人检测、语音识别等领域取得了优秀的研究成果<sup>[79]</sup>。深度学习的基本思想是通过复杂的网络模型以及相应的非线性变化，挖掘区别于浅层数据的抽象表示，以挖掘原始数据集的内在底层特征表示<sup>[80-81]</sup>。目前，基于深度学习算法的微观主体土地利用决策模型鲜有研究，国内外研究者主要运用深度学习算法预测数据变化，如欧定华等通过 PSR 模型获取生态安全模拟的特征向量，耦合 RBF 神经网络与克里金插值法，为预测生态安全提供一种新思路<sup>[82]</sup>。曹洪洋等基于 GIS 空间分析获取雅安市雨城区的降雨强度、降水量以及下垫面数据，通过深度神经网络模拟预测该城区的滑坡灾害情况<sup>[83]</sup>。

综上所述，土地利用模拟常用两种模型为 CA 与 ABM 模型，本文依据课题组前期基于 BDI 行为模型决策的研究，结合随机森林与 BDI 模型构建一个 RF-BDI 模型，克服转换规则设置较为刚性的问题，提高模型精度以及模拟效率，并实现机器学习辅助人工决策的半自动化模拟土地利用变化并以此分析机器学习算法应用于土地利用变化研究的优势及其不足。深度学习作为机器学习领域一个重要的研究热点方向，深度学习算法具有优秀的分类与预测能力。本文拟通过深度学习中深度神经网络方法构建土地利用变化模型，对比其与 RF-BDI 模型之间优缺点，以此探索深度学习算法与机器学习算法应用于乡村土地利用变化的优劣，实现一个全自动化模拟与预测土地利用变化平台，以期为未来的微观主体土地利用变化模型发展开拓一个新方向。

## 1.3 主要研究内容与技术路线图

### 1.3.1 主要研究内容

本文以村庄种植数据以及农户个体种植数据，结合土地年鉴、二调土地利用图、遥感影像数据等数据构建基础数据集，利用多智能体模型中 BDI 行为理论构建基础 Agent 决策模型，其次将机器学习中随机森林方法引入 BDI 模型中，构建 RF-BDI 模型，最后利用深度神经网络构建一个基于深度学习的土地利用变化模拟平台，并对比 RF-BDI 模型与深度神经网络模型二者之间优劣，以期为复杂人地系统模拟开拓一个新方向。



---

### (1) BDI 决策框架的构建

借鉴 BDI 有限理性决策模型已有研究，考虑农户间相互作用因素，构建农户有限理性个体决策模型来模拟其土地利用行为。以历年调研数据为基础数据，通过 BDI 决策框架设计农户 Agent 的状态集合、行为规则及其种植意图。

### (2) RF-BDI 决策框架的构建

首先构建随机森林模型，随机森林能够度量各个影响因素在土地利用演变过程中的贡献度，从而揭示微观农户行为对宏观土地利用变化的影响机制，并立足于 BDI 决策框架的基础上，对其决策规则进行调整，提高其模拟精度以及模拟效率。

### (3) DNN 决策框架的构建

依据现有深度神经网络方法，结合农户个体调研问卷数据、土地年鉴、土地利用图以及遥感影像等数据，依据 Keras 模块调整网络结构，并设置相关参数构建 DNN 模型，通过情景模拟法分析深度神经网络模型应用于研究复杂人地系统演变的可行性。

### (4) RF-BDI 模型与 DNN 模型对比研究

基于构建完成的 RF-BDI 模型与 DNN 模型，以陕西省米脂县高渠乡为例，对比 RF-BDI 模型与 DNN 模型模拟结果，揭示利用该模型进行土地利用演变模拟的优劣性。

#### 1.3.2 技术路线图

本文拟通过走访式农户调研获取农户权属和种植数据，并结合相应年份的遥感数据以及土地利用图，利用 BDI 决策结构，构建微观农户有限理性个体决策模型、RF-BDI 模型、DNN 模型，以模型模拟的方法，通过实例进行验证分析，探讨不同层次主体决策与区域土地利用变化之间相互关系，技术路线图如图 1 所示：

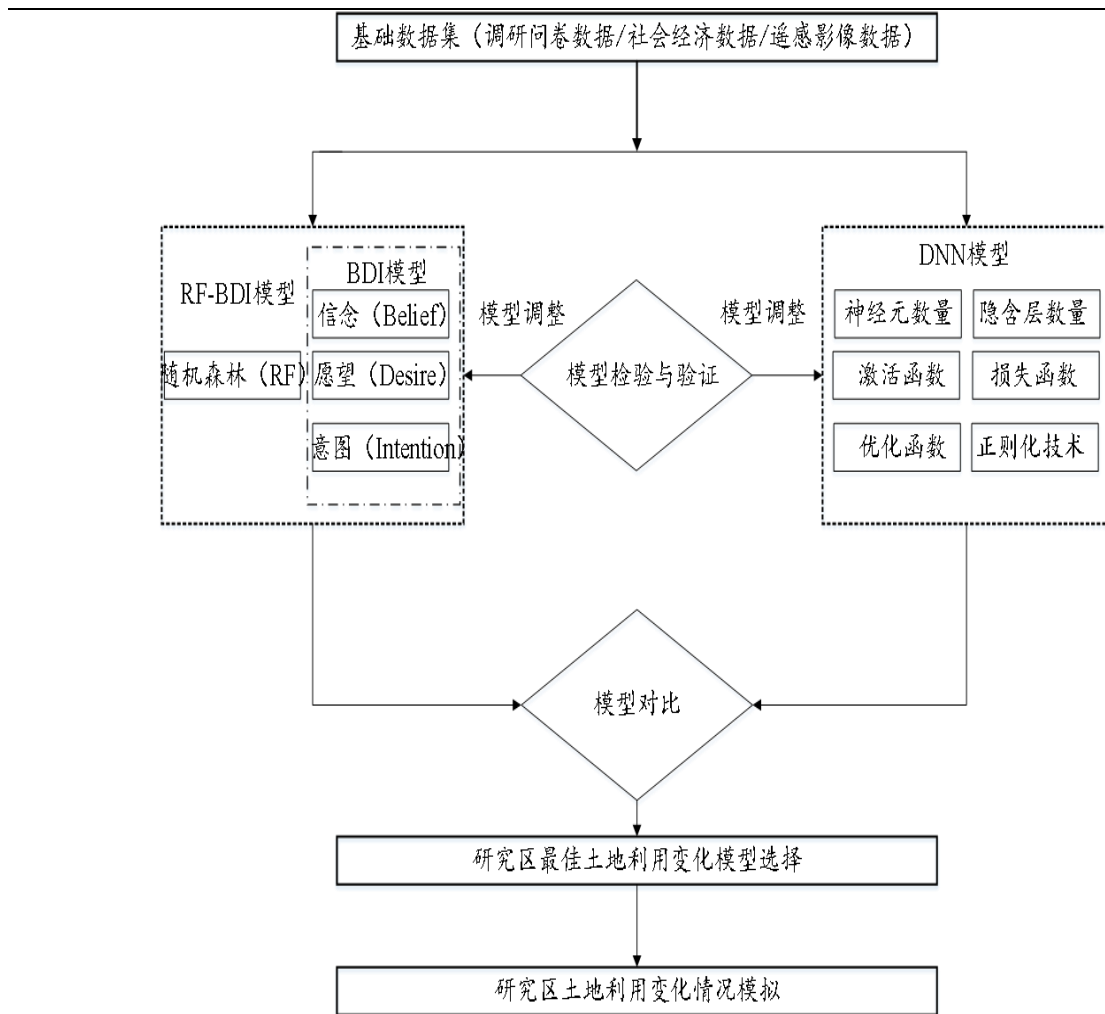


图 1 技术路线图

Fig.1 The technology route figure

## 1.4 研究创新点

### 1.4.1 随机森林与 BDI 决策模型的耦合

在众多机器学习算法中,随机森林算法除具备相应的分类以及挖掘客观规则的能力而且其可以对特征向量的相对重要性进行评估,因此耦合随机森林与 BDI 模型不仅能够有效的评价各影响因素的重要性而且可以挖掘农户的种植行为规则,结合随机森林与 BDI 决策模型构建 RF-BDI 模型可以有效提升工作效率。同时在 BDI 决策模型中,合理设置 Agent 转化规则是 BDI 决策模型的关键,通过随机森林方法修正 Agent 转化规则,避免 Agent 转化规则过于刚性。

---

#### 1.4.2 基于深度学习的土地利用变化模型

随着地理大数据的提出，机器学习用于模拟人地复杂系统遇到其相应瓶颈，深度学习比机器学习具有更好的学习能力，在处理回归预测和分类等问题上具有良好的表现，深度学习目前主要用于处理客观数据，将其用于模拟微观主体的决策行为鲜有研究。基于深度学习构建微观主体土地利用决策模型，挖掘农户的决策行为规则，是将深度学习应用于复杂人地系统模拟的一次尝试，是对未来土地利用变化模型发展的一次探索。

---

## 第二章 研究区概况与数据处理

### 2.1 研究区概况

米脂县位于陕西省北部，东经  $109^{\circ}49'$ ~ $110^{\circ}29'$ ，北纬  $37^{\circ}39'$ ~ $38^{\circ}5'$ ，东西长 59 km，南北宽 47 km，区划总面积  $1173.80\text{ km}^2$ 。黄河一级支流无定河穿境而过<sup>[17]</sup>。总体地势呈现东西高中间低，平均海拔 1049.0m，最低海拔约为 843.2m，最高为 1252m。米脂县毗邻区域中心城市榆林，距榆林城区仅 78 km。包西铁路、榆绥高速公路、242 国道纵贯南北，县城与太中银铁路、青银高速公路、307 国道绥德枢纽也仅相距约 20 km。县域在国家“三纵五横”流通大通道西线呼昆流通大通道和西北北部流通大通道交叉点上，交通便利，区位优势较为突出。米脂县地处黄土高原腹地，属典型的黄土高原丘陵沟壑区，地貌主要以峁、梁、沟、川为主，土质主要是黄绵土，土层深厚，结构疏松；气候属中温带半干旱气候区，全年雨量不足，气候干燥，生态环境较为脆弱<sup>[71-72]</sup>。该县包括 13 个乡镇，396 个行政村，总人口 23.5 万，其中农业人口 20.8 万人。“十二五”以来，米脂县农业基本形成了红葱种植基地、小杂粮种植区以及休闲农业生态示范区等格局。

米脂县全年平均降雨量较低，雨量较少且多暴雨，降雨夏季多冬季少，气温昼夜温差大，是典型的半干旱大陆性季风气候。年平均气温 3.3 摄氏度，温差较大，夏季最高气温与冬季最低气温相差约为 70 摄氏度，无霜期共有 165 天，降雨量较少，年平均降雨量为 440mm，最大年份降雨量为 704mm，最小年份为 186mm，水土流失问题较为严重。

米脂县 2016 年，生产总值为 42.45 亿元，人均生产总值为 27 867 元，同比增收 17.66%。财政总收入为 2.23 亿元，同比增收 9.34%，地方财政收入 8 380 万元，年均增长 13.0%。城乡居民人均可支配收入分别达到 29 100 元、9 670 元，年均增长 8.5% 和 8.7%。全社会固定资产投资累计完成 144.4 亿元，较“十一五”年均增长 28.3%。全县三次产业结构为 14: 33: 53，与“十一五”末相比，一产占比略有下降、二产快速上升、三产小幅提高<sup>[73]</sup>。

高梁乡地处米脂县北部，土地面积共  $72.4\text{ km}^2$ ，辖 20 个行政村，总人口约 1 万，其中耕地面积最大，约占总面积的 38%，草地次之，约占总土地面积的 28%，林地面积与园地面积接近，约占总土地面积的 12%，城镇居民面积与城镇建设用地约占土

地总面积的 3%，水域面积最少约占土地总面积的 1%，如图 2 所示。高渠乡属典型的黄土高原丘陵沟壑区农业乡镇。高渠乡种植以土豆和红葱等传统经济作物为主。陕西省农业厅在 2010 年将高渠乡确定为第三批“一乡一业”示范乡镇。本团队在高渠乡进行了长达十年的调研，积累的丰富的调研资料。依据 2017 年对该乡调研，村庄整体调研问卷 20 份，有效问卷 20 份。其中包括村庄整体种植情况，不同作物种植面积，不同农户类型。高渠乡农户个体调研问卷共 389 份，有效问卷 377 份，其中主要包括个人种植作物类型，不同种植作物的种植面积。由此可知，高渠乡种植情况复杂，且农户种植行为具备明显的随机性以及受政策导向影响明显，将该乡镇作为研究区，可以有效检验模型的准确性

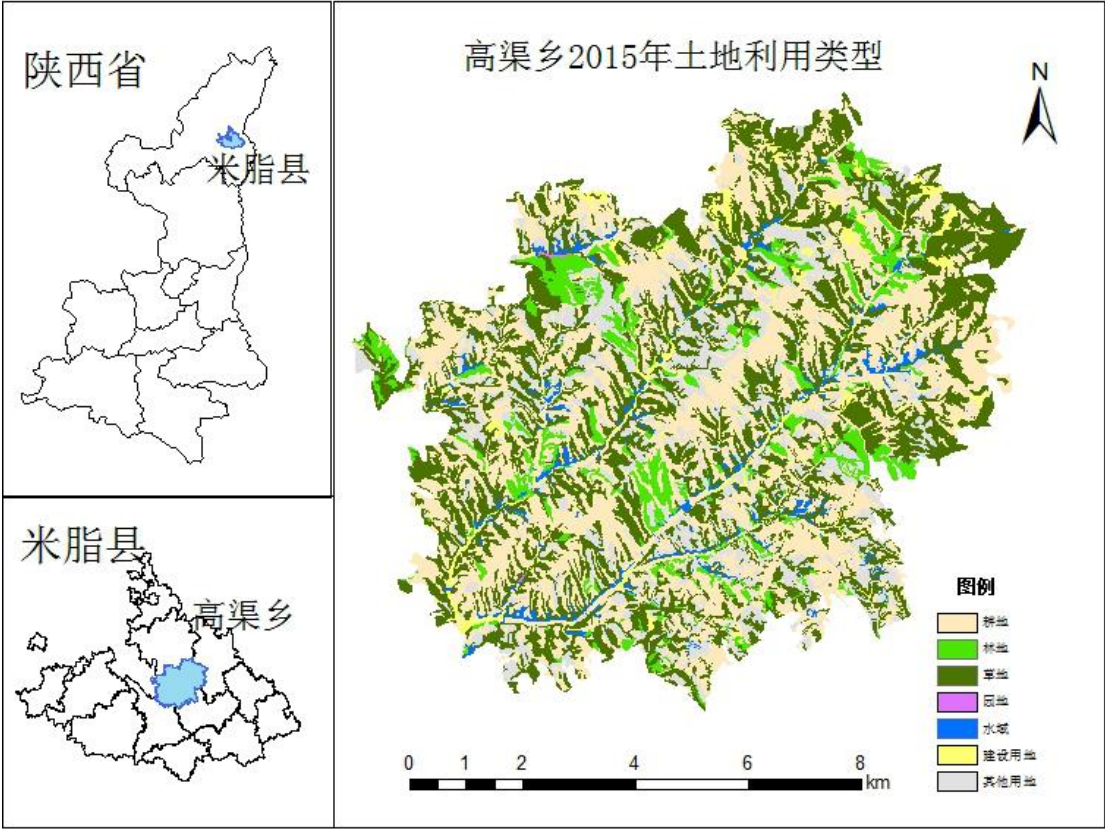


图 2 研究区区位图  
Fig.2 The location of the study area

2.2 数据来源

(1) 行政区边界、道路等基础数据源于 2009 年米脂县第二次全国土地调查数据（简称二调数据）1:10000 土地利用类型图，并在 2015-2017 年实际调研中

---

对该基础数据进行完善修正。

(2) 通过中科院计算机网络信息中心地理空间云获取米脂县 DEM 数据。通过 GPS 测点, 结合 30m\*30m 分辨率 DEM 数据, 在 Arcgis 中通过重采样工具获取米脂县 5m\*5m 分辨率的 DEM 数据, 通过 GIS 空间分析获取该村落的坡度与坡向数据。

(3) 通过研究区高渠乡实地调研村庄整体问卷数据以及农户个体问卷数据或者村庄社会经济数据, 高渠乡作为研究区, 2015-2017 年课题组每年 7 月-8 月均对高渠乡的 20 个村庄进行入户调研, 获取 60 份村庄整体问卷以及 389 份农户个体种植情况问卷;

(4) 种植农户个体社会经济数据。源于研究区实地调研问卷数据, 调研采用 PRA 参与式访谈和入户调查相结合的方式, 主要包含农户个体种植作物类型、农户种植面积、农户年龄、农户家庭收支情况、农户种植行为以及政策对农户种植行为影响等基础数据。

## 2.3 数据处理

### 2.3.1 RF-BDI 模型数据处理

1、自然条件影响因素处理, 根据米脂县 5\*5m 的 DEM 数据提取 RF-BDI 模型所需高程、坡度、坡向和地形起伏度等自然因素, 将其输入随机森林模型, 得出自然条件因素贡献度排序, 并选取其中贡献度较大的影响因素作为 RF-BDI 模型的自然条件影响因素数据。

2、社会经济影响因素处理, 根据研究区 2015 年, 2016 年, 2017 年农户个体问卷以及村庄整体问卷整理获取农户种植作物类型, 农户种植面积, 农户农业投入与产出比等数据, 同自然因素处理选取其中贡献度较大的影响因素作为社会经济影响因素数据。

3、结合 2016 年高渠乡调研数据、遥感影像解译数据、GPS 测量数据和实地手绘数据获得高渠乡农户权属图, 为模拟农户与其耕地一一对应做数据准备。通过 2017 年遥感影像以及实地调研获取 2017 年高渠乡土地利用图, 用于逐点验证模型模拟效果。

### 2.3.2 DNN 模型数据处理

1、在 RF-BDI 模型的数据基础之上, 为加快深度神经网络模型训练速度, 需要

---

对输入网络的样本数据进行标准化，本文采取独热编码（One-Hot Encoding）对其标准化，独热编码是利用多个状态寄存器对每个样本数据进行独立编码，每个样本都有且仅有一个独立的寄存器位。即对于一个具有  $M$  个  $N$  类的特征集合，经过独热编码标准化后将其转为  $M*N$  的二维特征集合。

2、将 DNN 模型模拟数据导入 ArcGis，预测高渠乡 2017 年的土地利用变化图。通过与高渠乡当年实际土地利用图进行对比以验证深度神经网络模型模拟效果，并对网络模型做出相应调整。

---

### 第三章 RF-BDI 模型的构建与模拟

以人地关系为核心的生态脆弱区土地利用变化是全球变化与可持续发展研究的热点问题之一，农户作为从事农业生产活动的主要载体，其决策行为将直接影响宏观层面的土地利用变化<sup>[70-75]</sup>，因此基于微观土地利用主体的模型模拟是研究土地利用演变的主要方式之一，ABM 模型能够准确模拟 Agent 决策行为且易于建模分析，成为了当前研究人地系统演变的主流模型。ABM 模型不仅能够模拟主体之间及其与所处自然环境相互作用，而且能够刻画复杂土地系统演变过程中影响主体决策的因素以及决策行为规则。而 BDI 行为理论作为一种能够表达 Agent 在信念、愿望和意图等状态集合的认知结构，BDI 行为理论能够详细模拟围观主体的决策行为而且具有灵活、真实的逻辑推理特性。

BDI 模型的核心问题是确定影响因素以及设定转化规则。传统 BDI 模型是基于经验获取转换规则，该规则设定较为刚性，不能精准模拟围观主体在人地系统演变过程中的决策行为。随机森林算法是机器学习领域中集成学习算法的典型代表，其具有构建简单、学习速度快、对复杂非线性数据具有良好的分类能力且对存在缺失值的数据具备良好的鲁棒性以及防止过拟合等优点，被广泛应用于处理预测、特征选择、分类等问题。随机森林还能够度量土地利用变化模拟过程中各个影响因素对模拟结果的贡献度，从而分析各个影响因素在人地系统演变过程中的作用。目前已有研究将随机森林算法与 CA 模型结合基于宏观视角研究城镇边界扩张<sup>[45-49]</sup>，但耦合随机森林算法与 BDI 模型研究基于农户视角的乡村土地利用变化还不多见。因此，本章将随机森林算法与 BDI 模型进行耦合，可以有效解决 BDI 模型中的两大核心问题。其一，通过随机森林算法确定 BDI 模型中影响因素的贡献度大小，以此确定最优影响因素并对其产生的影响进行解释，同时剔除无关影响因素，提高模型的准确度。其二，随机森林可以依据变量之间的内在联系自动提取变量的转换规则并对该规则进行人为微调，故可以达到克服转换较为刚性的问题。旨在通过 RF-BDI 行为决策模型提高对研究区土地利用变化情形的模拟精度以及揭示宏观土地利用变化的微观驱动机制。



---

### 3.1 相关概念说明

#### 3.1.1 Agent

Agent 起初源于人工智能，目前，Agent 在计算机、地理学、社会学等各个领域均有广泛应用。Agent 在不同的领域具有不同的概念，最为权威的概念是由 Wooldridge 提出的。Agent 在特定环境中，其能够依据相应的转换规则以达到预期的目标，Agent 具有复杂性、独立性和自组织性等特性。Agent 在本文中代指乡村土地利用变化中的独立个体，即是农户，并以农户的行为规则为核心构建相应的模型，模拟与预测整体乡镇的土地利用变化。

#### 3.1.2 BDI 行为理论

BDI 行为理论是心理学中刻画微观主体在 Belief、Desire 和 Intention 等方面思维状态的理论，BDI 行为理论主要用于模拟 Agent 的决策过程以及刻画不同的决策行为对结果产生的作用等方面。BDI 行为理论主要包含信念、愿望和意图等三个主要影响微观主体决策的状态集。Wooldridge 将这三个因素定义为：信念指主体对自身以及目前所处环境的认知集；愿望是主体希望达到的状态；意图是指主体为达到其期望的状态而付出的行动。BDI 行为理论在表达主体决策行为时，不仅能够清晰的刻画主体决策行为的形成原因，而且能够表达其决策行为的产生的结果，并对其结果进行详细的分析。除此之外，BDI 行为理论没有对算法进行强制要求，为 BDI 行为理论与其他算法进行耦合提供了便利。目前已有学者基于传统 BDI 行为理论与 PCA 算法进行耦合构建 PCA-BDI 模型，为本文构建 RF-BDI 模型提供了相应的思路。

#### 3.1.3 随机森林

随机森林是机器学习中集成算法的典型体现，随机森林通过多个分类器结合而成，在每个分类器的分类过程中，都会从初始特征向量中随机抽取  $N$  个向量作为特征子集，以这  $N$  个特征向量中贡献度最大的因素进行分类。随机森林的主要思想集中于两个随机方式上，通过随机重采样技术构建多个分类器以及随机选取特征子集构建候选特征向量，最终通过少数服从多数的举手表决方式得出其分类结果。随机森林算法具有构建简单、学习速度快、对复杂非线性数据具有良好的分类能力且对存在缺失值的数据具备良好的鲁棒性以及防止过拟合等优点，被广泛应用于处理预测、特征选择、分类等问题。

本章节对随机森林进行训练主要是基于目前国际上流行的机器学习包 **SKLearn**。在构建随机森林时主要涉及两个自定义的参数：决策树的数量以及预测变量的数量。其中决策树的数目主要是指随机森林随机重采样的次数；预测变量的数量是指随机森林算法分类器的特征向量的数量。随机森林的随机重采样是有放回的随机抽样，因此约有三分之一的训练数据无法选取，而将其作为测试数据，检验随机森林的分类效果。为确定随机森林两个参数的值，需要对其进行 **OOB** 袋外无偏估计，检验随机森林在不同参数时的模拟精度，以便调整其参数获取最优的模拟效果。

## 3.2 研究方法

### 3.2.1 基于 BDI 决策框架的农户土地利用决策模型构建

#### (1) 信念构建

信念是微观主体对自身及周围环境的认知集合。高渠乡是典型的黄土丘陵沟壑区，结合实地调研发现，影响农户种植策略的主要影响因素表现为自然条件，其中主要包括坡度、坡向、高程、地形起伏度以及距离村落主要道路的距离，因此构建农户 Agent 信念的公式为：

$$B_{t+1} = f\{P_t, D_t\} \quad (3.1)$$

其中：

$B_{t+1}$  为农户 Agent 的信念集；

$P_t$  为农户 Agent 对周围环境的认知和需求标准；

$D_t$  为农户 Agent 到主要道路的距离集合，其中主要包括到农村主道路的距离以及到县城道路的距离。

$P_t$  表示为如下函数：

$$P_t = f\{Slope_t, Aspect_t, elevation_t, Relief_t\} \quad (3.2)$$

其中：

$Slope_t$  表示农户 Agent 地块所处位置的坡度；

$Aspect_t$  表示农户 Agent 地块所处位置的坡向；

$elevation_t$  表示农户 Agent 地块所处位置的高程；

$Relief_t$  表示农户 Agent 地块所处位置的地形起伏度。

---

## (2) 愿望构建

愿望是微观主体依据自身信念而期望达到的目的，为了体现农户的有限理性，在愿望模块中添加政策影响指数 (*Policy*)、能力指数 (*Ability*)。结合实地调研情况可知，当地政策会使农户在种植策略中产生一个潜在策略，且此策略是优于农户传统种植策略，但农户是否会执行潜在策略要以自身种植能力进行判定，因此农户 Agent 的愿望如下：

$$Desire_t = Policy_t * Ability_t \quad (3.3)$$

$Policy_t$  为政策和农业措施对农户 Agent 决策产生的影响指数，若农户受到影响则为 1，否则为 0； $Policy_t$  参数只是影响农户 Agent 潜在的土地利用方案，但农户 Agent 是否进行土地转化以及转化量主要由  $Ability$  指数决定。 $Ability$  参数的构成：

$$Ability_t = PlantAbility_t * Important_t \quad (3.4)$$

$PlantAbility_t$  表示农户 Agent 在政策、农业措施以及自身的种植经验的影响下所表现出的种植能力，当农户具备种植作物  $t$  能力时为 1，反之为 0； $Important_t$  表示当前土地利用方式对农户 Agent 的重要性，可以表示为：

$$Important_t = \frac{Area_t * Income_t}{\sum_{i=1}^n Area_i * Income_i} \quad (3.5)$$

其中：

$Area_t$  表示土地利用类型  $t$  的面积；

$Income_t$  表示土地利用类型  $t$  的收入；

当土地利用类型  $t$  的重要性在所有土地利用类型最大时为 0，否则为 1。

在政策导向下，农户在自身具有相应的种植能力时，便会将其耕种地块中对其相对影响较弱的地块转换为政策倡导的土地利用类型，但其他对自身生计影响较大的地块仍按照农户传统的种植策略进行转化，在其认为自身种植能力不足时，则全部地块按照传统种植策略进行耕种。

## (3) 意图构建

意图农户 Agent 在自身信念与愿望的驱动下做出的决策，并为之付出相应的行动，具体为：

$$I_t = f\{Belief_t, Desire_t\} \quad (3.6)$$

根据实地调研得知,农户 Agent 对土地利用的意图具体表现为轮作策略和转化策略,对于农户的土地利用轮作计划。通过实际调研,发现当地农户主要采用土豆→杂粮→土豆的轮作方式。因此,本文的轮作参数采用该种土地利用的轮作方式。对于其转化策略主要包含两个层次,其一:向政策导向的耕种方式进行转化,在农户自身认为其具备种植政策倡导作物的能力时,会将其部分土地转化为政策导向的种植方式,以获取政府补助以及更高的经济效益。其二:依据传统种植策略进行转化,研究区主要有 4 种经济作物:小红葱、苹果、土豆和玉米。其中玉米主要作为牛的饲料;苹果是当地特色产业之一,但由于苹果收获时期较长,前期投入较大,当地自然灾害较为严重,农户对于苹果的种植较为保守,尤其是在当地缺少相应的补助措施时,农户种植苹果的可能性较小,这也是典型乡镇高渠乡苹果的种植量较少的主要原因。结合实地调研以及同时为了简化规则,将地形起伏度划分为伏度小、伏度中、伏度大 3 类,分别用 1、2、3 表示,距离乡村主要道路距离划分为距离近、距离中、距离远 3 类,分别用 1、2、3 表示。为表达两种因素的综合影响,采用如下规则进行表达:个位数代表地形起伏度类型,十位数代表距道路距离类型。例如 11 和 32 分别农户地块距道路距离近伏度小的条件和距道路远起伏度中的条件。依据研究区作物种植实际情况构建以下规则:土豆在自然条件 13、23、31 条件下保持不变,下一年作物仍然种植土豆;在不同于这 3 类自然条件下,下一年作物由土豆转化为杂粮。杂粮在 11、21、31 条件下,即地形起伏度小的条件下,下一年作物由杂粮转化为土豆;在不同于 11、21、31 情况下,种植作物保持杂粮不变。玉米、果园、红葱等 3 种土地利用类型默认保持不变。

### 3.2.2 基于随机森林的 RF-BDI 模型的构建

首先以高渠乡历史土地利用数据训练随机森林模型。本章选取陕西省米脂县高渠乡 2016 年土地利用数据作为训练数据,其中对其土地利用结果影响向量及获取方式见表 1,对高渠乡土地利用结果,玉米、杂粮、土豆、果树、红葱分别编码为 1, 2, 3, 4, 5。本模型以 Python 为编程语言,结合 Arcgis 中 Python 语言开发包 Arcpy 以及国际上流行的机器学习开源工具包 Scikit-learn,以高渠乡 2016 年土地利用数据为样本数据建立随机森林模型。

表 1 影响因素及获取方法

Tab.1 influence factor and acquisition methods		
变量类型	变量	获取方式
因变量	土地利用类型	遥感分类
自然因素变量	坡度	Arcgis 空间分析功能获取
	坡向	
	地形起伏度	
	高程	
距离变量	距农村道路距离	Arcgis 距离分析
	距乡镇道路距离	
人文因素变量	政策	实地调研获取
	能力指数	

目前，基于团队前期对高渠乡长达十年的研究，选取 4 个自然条件因素以及 4 个社会经济因素，其中自然条件因素主要是由 DEM 数据、GPS 实地测点以及结合 Arcgis 软件进行空间分析获取。社会经济因素主要包括道路距离、政策影响以及能力指数等，其中距离道路的距离，本章只选取对农户影响较大的农村道路以及乡镇道路，主要由实地调查、二调数据以及结合 Arcgis 软件中距离分析工具获取。政策影响以及能力指数主要是由团队长期的走访时调研，结合乡村整体调研问卷以及农户个体调研问卷获取。对农户决策行为进行模拟由于农户决策属于主观决策行为，故需要大量有效数据。本文仅可能对农户决策产生影响的因素及调研其决策行为，农户决策行为的直观体现即是宏观层面的种植作物的更改，本文仅考虑从事农业活动的农户决策行为。

依据调研获取的现有数据对随机森林训练主要涉及两个参数 `ntree` 和 `maxFeatures`，`ntree` 是随机森林算法中分类器的数量，模拟效果会随着决策树的数量增多逐渐变好，但其需要处理的时间也会相应增加。除此之外，当决策树的数量达到临界值时，模拟效果将不会继续增加且由于计算机硬件的限制，模拟效果会呈现下降趋势。综合运行时间以及模拟趋势即可以确定最优 `ntree` 的数值。`maxFeatures` 是决策树进行分类时候选特征向量的最大数量。根据经验，在处理分类问题时，可以先将 `maxFeatures` 设置为最大的影响参数数量，先确定 `ntree` 的数量，后确定 `maxFeatures` 会取得更为理想的效果。

随机森林依次分类每条样本数据，综合多个决策树的预测结果，通过举手表决机制得出最终的模拟结果，由图 3 可知决策树的数量会对随机森林算法的模拟效果产生明显的影响。将 `maxFeatures` 设置为最大影响因素数目时，决策树的数量为 1 时，仅有 50.5% 的预测精度，伴随决策树数数量增加，预测精度迅速提高，当决策树的数目为 800 时，预测精度到达 81.3%，随着决策树数量的增多，预测精度仍会提升但最后都没有超过 81.5%，综合考虑计算机运行速度及预测精度，本文选取 1200 作为随机森林中树木的数量。




图 3 分类精度与树的数量之间的关系

**Fig.2 Relationship between classification accuracy and the number of trees**

随机森林中每个决策树均会从  $N$  个原始变量中随机选取 `maxFeatures` 个随机变量作为此颗决策树的特征向量，并依据此特征子集进行节点分裂以及结果分类，因此 `maxFeatures` 值不同，随机森林将会取得不同的预测结果，如图 4 所示。在决策树数量确定时（本文选取决策树数量为 1200），随机森林的预测结果随着特征向量的数目增多，预测精度呈现先增加后减少的趋势。当特征向量为 1 时，预测精度仅为 47.2%。当特征向量为 5 时，随机森林取得最高的预测精度为 83.2%，因此本文选取的特征向量数目为 5。




图 4 分类精度与预测变量个数之间的关系

**Fig.4 Relationship between classification accuracy and the number of predictive variables**

在随机森林训练完成后，可以通过袋外数据对其特征向量评估其贡献度，以期寻找对土地利用变化最为重要的影响因素并解释各个影响因素在土地利用变化过程中的决策作用。各个影响因素在土地利用变化中的相对贡献度可以通过决策树分裂过程中使用影响因素的先后顺序来确定。越靠近决策树根节点所使用的影响因素对该此决策将更为重要。在本文中随机森林的变量重要性如图 5 所示，坡度、地形起伏度、距农道路距离、政策、能力指数等影响因素对农户土地利用行为有较大影响。




图 5 变量重要性度量

**Fig.5 Variable importance plots for classification random forest**

传统 BDI 模型信念模块中，通常设置较多的自然与人文因素以分析农户决策行为，但在意图模块中设置农户土地利用行为转化规则时，因人力有限或计算复杂度等因素影响，通常简化影响因素，但其简化过程没有明确的算法支撑，通常是根据地调研经验简化。以 RF-BDI 模型模拟土地利用变化时，首先需要进行随机森林训练，

随机森林算法为 BDI 信念模块中影响因素的筛选提供了有力的算法支撑，以陕西省米脂县高渠乡为例，在 BDI 模型信念模块中选取了坡度、坡向、地形起伏度、道路距离、能力指数、政策影响等影响因素，但通过随机森林算法变量重要性筛选可以得出，选取坡度、地形起伏度、距农村道路距离、政策、能力指数等 5 个影响因素时，模拟效果最佳。

传统 BDI 模型意图模块中，设定农户土地利用行为转化规则时，通常是将简化后的影响因素进行自然断点法分级，如将地形起伏度划分为伏度小、伏度中、伏度大 3 类，此种设置方式过于刚性，对预测结果影响较大。在 RF-BDI 模型中，需要对随机森林的结果进行可视化，在机器学习 Scikit-learn 模块中没有提供相应的可视化方法，只能将随机森林的结果拆分成单棵决策树结果进行可视化。将决策树可视化之后根节点的数值作为意图模块中影响因素分类的指标，如依据决策树中根节点中能力指数的分类阈值为 0.7，将能力指数分为具备相应种植能力农户与不具备相应种植能力农户两类。

根据随机森林选择 BDI 模拟中的特征向量以及挖掘农户土地利用行为的转化规则，并对其转化规则进行可视化以方便人工调整转化规则。本文模拟了陕西省米脂县高渠乡 2016 年土地利用情况，预测了高渠乡 2017 年土地利用情况。土地利用变化情形模拟是通过 Arcgis 中 Arcpy 模块与机器学习 scikit-learn 模块实现的，随机森林可视化是通过 Python 语言中 Graphviz 模块实现。

### 3.3 结果分析

#### 3.3.1 BDI 决策模型结果分析

以 BDI 决策模型对高渠乡 2016 年种植情形进行模拟，模拟结果如图 6 所示，2016 年高渠乡总体模拟准确率约为 68%，果树与其他种植类型的模拟效果较差，其中其他种植类型明显低于平均准确率，果树整体模拟精度为 61%，主要是由于高渠乡从 2016 年开始发展果树种植，农户受政策影响开始将部分种植用地转变为果园，但 BDI 决策模型模型规则设定时对政策影响的考虑较弱，主要考虑农户自身的种植习惯。其他种植类型主要来源于农户自身的随机种植以及应急种植行为，BDI 决策模型中并没有考虑随机种植行为，但仍有 50% 的准确率主要是因为以上种植类型中没有出现的类型均划为其他种植类型，故农户没有将其他种植类型的地块转换为已知的耕种类型，均算做预测准确。玉米、土豆、杂粮符合设定的转换规则均超过 70% 的准确率。






图 62016 年 BDI 模型模拟准确与失误图

Fig.6 The accuracy and the fault of the simulation for the BDI model in 2016

以 BDI 决策模型对高渠乡 2017 年土地利用类型进行模拟,模拟结果如表 2 所示, BDI 决策模型对高渠乡 2017 年模拟结果较差,整体模拟结果为 51%,除玉米外,其他种植类型的模拟效果均不理想,其中整体模拟效果不理想是因为高渠乡政府 2017 年大力发展苹果产业,农户受到政策及同类农户影响将大部分种植类型转换为果树,杂粮与土豆模拟效果不佳除受到种植果树影响之外还因为高渠乡 2017 年没有按照既定轮作规则进行轮作,即本应轮作为杂粮的种植类型仍种植土豆。

表 22017 年 BDI 模型模拟准确与失误图

Tab.2 The accuracy and the fault of the simulation for the BDI model in 2016

指标	玉米	杂粮	土豆	红葱	果树	其他
准确率	0.72	0.48	0.60	0.57	0.55	0.29
失误率	0.28	0.52	0.40	0.43	0.55	0.71

结合 BDI 决策模型对高渠乡 2016 年与 2017 年模拟情况可知, BDI 模型能够模拟农户的种植行为但其模型设定的转换规则受时间序列影响严重,即 BDI 决策模型有一定的时间局限性。在对高渠乡 2016 年与 2017 年模拟中,其他种植类型的模拟效果均不甚理想,说明 BDI 决策行为虽然可以模拟部分农户的决策行为,但对农户的突发决策以及随机决策缺乏相应的模拟能力。

### 3.3.2 RF-BDI 模型结果分析

使用 RF-BDI 模型对土地利用情况进行模拟,需要当年实际土地利用情况对其模拟结果进行检验,一种简便的检验方式即是通过 2016 年与 2017 年陕西省米脂县高渠乡土地利用数据与 RF-BDI 模型模拟结果进行精度检验。本章采用逐点对比方式对

RF-BDI 模型模拟结果进行精度检验以便评估 RF-BDI 模型模拟效果，并与传统 BDI 模型模拟结果进行对比，分析 RF-BDI 模型用于土地利用模拟的可行性与有效性。




图 7 不同时期模拟精度

Fig.7 Simulation accuracy of different period

由图 7 可知，在时序预测中传统 BDI 模型预测精度呈现下降趋势，最高精度为 68.5%，RF-BDI 模型预测精度呈现平稳趋势，最高精度为 83.2%。主要由于传统 BDI 模型规则设定时即确定农业种植类型，对于新增加作物类型预测结果较差即 BDI 模型对随机因素的拟合效果较差，且 BDI 模型设计规则时较难综合考虑政策导向，难以对自身进行及时修正，高渠乡近年来大力发展苹果产业种植，在政策导向起主导作用时，传统 BDI 模型预测效果明显低于 RF-BDI 模型。RF-BDI 模型预测精度更高，且对时序数据预测具有明确的优势，说明 RF-BDI 模型对随机因素有较好的泛化能力，能够及时调整自身的转化规则对其进行相应模拟，故 RF-BDI 模型用于模拟土地利用状况时与实际土地利用情况更加一致。传统 BDI 模型在高渠乡 2015 年土地种植状况模拟效果最佳，但与 RF-BDI 模型模拟精度仍有较大差距，由此可见 RF-BDI 模型相对传统 BDI 模型，RF-BDI 模型即能够较好的模拟时序数据又能够取得较好的模拟效果，比传统 BDI 模型具备一定的优势。

为了具体分析 RF-BDI 模型模拟效果优劣，需要对 RF-BDI 模型逐年模拟效果进行对比分析，RF-BDI 模型对高渠乡 2015 年、2016 年、2017 年农业土地种植类型预测正确率如下表 3 所示，其中农业的主要种植类型为土豆、杂粮、玉米、果树、红葱等，考虑农户的随机种植行为以及农户的较少种植的种植作为类型，将其归为其他。

表 3 随机森林模拟精度

Tab.3 Simulation accuracy of random forest

	2015 年	2016 年	2017 年
土豆	83.2	80.7	80.6
杂粮	83.3	80.6	80.3
玉米	79.3	78.2	77.1
果树	80.2	70.3	65.4
红葱	79.9	77.4	79.8
其他	93.3	79.2	70.4

高渠乡处于黄土丘陵沟壑区，主要种植粮食作物为土豆与杂粮，RF-BDI 模型在预测土豆与杂粮时，均表现稳定，预测准确率约为 80%。由表 6 可知，RF-BDI 模型在预测果树时，2016 年呈现下降趋势，主要是由于政策导向，政府大力推广种植果树。2017 年果树预测准确率为 65.4%，虽然模拟效果不如其他种植类型，但没有出现 BDI 模型中大面积预测错误的情形，说明 RF-BDI 模型会自动学习调整当前模拟规则，对预测结果进行反馈。在其他土地类型上，RF-BDI 模型可以较好处理随机种植行为，虽然呈现一种下降趋势，但整体预测准确率均高于 BDI 模型预测准确率。在整体土地利用类型预测准确度，6 种土地利用类型，除其他与果树外，其准确率分布平稳，说明 RF-BDI 模型可以较好的模拟高渠乡土地利用变化情形。

以高渠乡 2015-2017 年模拟效果对比分析 RF-BDI 模型与 BDI 决策模型得出以下结论，RF-BDI 模型与 BDI 模型均可以较好的模拟农户的决策行为，但 RF-BDI 模型模拟效果高于 BDI 决策，且 RF-BDI 模型为分析影响因素对农户决策过程提供了算法支撑，不仅是基于经验确定农户的决策规则。在对高渠乡的土地利用时间变化中，RF-BDI 模型模拟效果远高于 BDI 模型，主要是因为 RF-BDI 模型具备一定的自我调节能力，即农户受到政策影响开始将其他种植类型转变为果树时，RF-BDI 模型能对其作出相应的规则调整，而 BDI 模型的规则设定较为刚性，在规则设定之后难以对突发决策作出相应的反馈。最后，BDI 模型通常放弃模拟农户的随机种植行为，但基于农户视角研究土地利用变化，短期内农户随机种植行为不会对模拟结果产生较大影响，但长远来看农户随机种植行为将会对模拟结果产生明显影响，而 RF-BDI 模型对农户随机种植行为有一定的模拟能力，故 RF-BDI 模型用于模拟人地系统演变不仅能提高模拟精度而且有助于解释其演变过程中的驱动机理。

---

### 3.4 RF-BDI 模型程序实现

本文构建随机森林算法是基于 Python 开发语言的第三方扩展模块 Scikit-Learn 实现，在 Scikit-Learn 中提供给我们两个随机森林类，即 `RandomForestClassifier` 和 `RandomForestRegressor` 类，其中本文主要用于预测土地利用变化情形，即是一种多分类问题，故采用 `RandomForestClassifier` 类。构建随机森林代码如下：

```
sklearn.ensemble.RandomForestClassifier(estimators=1200,  
criterion='gini',  
max_depth=None,  
min_samples_split=2,  
min_samples_leaf=1,  
min_weight_fraction_leaf=0.0,  
MaxFeatures='5',  
max_leaf_nodes=None,  
min_impurity_decrease=0.0,  
min_impurity_split=None,  
bootstrap=True,  
oob_score=False,  
n_jobs=1,  
random_state=None,  
verbose=0,  
warm_start=False,  
class_weight=None)
```

其中主要用到的参数为：

`estimators`，子分类器的数量即决策树的数目；

`Criterion`，判断节点是否继续分裂的算法；

`MaxFeatures`，节点分裂时候选特征向量的最大数目；

其余参数采取默认即可。

构建随机森林模型之后，可以在其基础之上进行重要性评估(用于筛选出对预测效果影响排序)，主要使用到 `RandomForestClassifier` 类中的 `feature_importances_` 属性，由于需要对结果进行可视化，因此需要用到 `matplotlib` 模块，代码如下：

---

```
importance=forest.feature_importances_  
ShowImportance=np.argsort(importances)[::-1]  
plt.bar(range(X_fit.shape[1]),importances[ShowImportance],color='lightblue',align='center')  
  
plt.xticks(range(X_fit.shape[1]),feat_labels,rotation=90)  
plt.xlim([-1,X_fit.shape[1]])  
plt.tight_layout()  
plt.show()
```

### 3.5 本章小结

结合随机森林与传统 BDI 行为决策模型构建随机森林 BDI 模型，以陕西省米脂县高渠乡为例，基于 Python 语言的 scikit-learn 模块与 Arcgis 中 Arcpy 模块对农户土地利用行为进行模拟，并与传统 BDI 模型对比得出以下结论：在模拟精度上，RF-BDI 模拟较传统 BDI 模型有较大提升，总体精度提高了 14.7%。在人地系统的演变驱动机理上，RF-BDI 模型解释了各影响因素在农户决策中影响占比，为探索宏观土地系统演变的微观驱动机制提供了一种新思路。在农户转化规则设定上，RF-BDI 模型克服了 BDI 模拟转化规则较为刚性的做法，并为规则调整提供了一种新方式。RF-BDI 模型不仅取得了更高的模拟精度且没有增加数据的运算量。综上所述，RF-BDI 模型用于模拟农户土地利用行为具备可行性与有效性。

需要说明的是，虽然 RF-BDI 模型相较于传统 BDI 模型有明显的进步，但其模拟精度仍有 20% 的提升空间，还不能有效解释农户的随机种植行为以及影响因素。本文将在现有数据的前提下，尝试利用深度学习算法构建土地利用变化模型，试图探讨农户的正常及随机行为，并对比分析 2 种方法的优劣，为后续更加准确模拟土地系统的演变奠定基础。

---

## 第四章 基于 DNN 的农户土地利用行为模型构建

虽然 RF-BDI 模型提高了模拟的精度，但 RF-BDI 模型对农户的随机种植行为的忍耐性较差，故本章拟通过深度学习算法构建一个土地利用模拟以解决该问题。相较于其他机器学习方法，深度学习分类能力更强。目前，深度学习算法是以 BP 神经网络为基础的网络模型发展而来，其中主要包括深度神经网络模型，卷积神经网络模型，递归神经网络模型等算法。

深度神经网络模型善于从原始输入数据中提取研究对象的客观规律，同时在特征提取和时空建模上比浅层非线性模型具有明显的优势，而且具有良好的泛化能力。目前深度神经网络在图像分类，目标检测，语音识别等领域取得了卓越进展。深度神经网络具备很强的学习能力，可以更好地模拟农户 Agent 决策行为，本章拟对比 RF-BDI 模型与 DNN 模型模拟效果，探究使用 DNN 模型模拟农户土地利用行为的可行性与精确性。

以陕西省米脂县高渠乡为例，拟通过深度神经网络模型模拟微观主体土地利用决策行为。首先，以高渠乡 2016 年土地利用数据为参照，考虑地形起伏度和距道路距离等两个影响因素，对比分析 DNN 和 RF-BDI 模型模拟 2016 年的模拟效果；其次，综合考虑坡度、坡向、高程、距农村道路距离、距居民点距离和距公路距离等多种影响因素，对比分析 BP 神经网络和 DNN 的模拟效果；最后，以实际作物间的转化为基础，探讨不同层次和神经元数量 DNN 的模型效果，以期探索 DNN 改进农户土地利用决策模型的可行性和有效性。

### 4.1 相关概念

#### 4.1.1 相关名词解释

##### （1）深度神经网络

以目前深度学习研究来看，深度学习算法主要是以神经网络为基础发展而来的各种网络模型。神经网络模型主要包括输入层、隐含层、输出层三个组成部分。深度神经网络，从字面上理解就是很深的神经网络模型，主要是指其具有多层隐含层，从而使网络模型复杂化。深度神经网络可以通过其复杂的网络结构以及相应的非线性变换对原始输入数据集进行逐层提取其内在特征，将其浅层的特征表示抽象为高层的特征

---

表示。

深度神经网络关键组成部分包括：隐藏层数量、隐含层神经元数量、激活函数、优化函数、BP 机制、过拟合等方面，本章将通过国际上主流的深度学习 Keras 模块设计一个深度神经网络模型并对其网络结构进行调整，以陕西省米脂县高渠乡 2017 年土地利用图检验深度神经网络模型的模拟效果。

## （2）激活函数

深度神经网络模型的组成部分之一，深度神经网络模型中每层隐含层有且仅有一个激活函数，通过激活函数将多次线性运算的结果抽象为更高层的特征表示。深度神经网络中每层隐含层的激活函数不必相同，激活函数应该具有易于计算、均值为零且不会饱和等特点，常见的激活函数包括：Sigmoid 函数、tanh 函数、ReLU 函数、ELU 函数、MAXOUT 函数、Softmax 函数等，其中 Sigmoid 函数是最为基础的激活函数，主要用于处理二分类问题；与其对应，Softmax 函数主要用于处理多分类问题。

## （3）优化函数

大部分深度神经网络模型以及相关深度学习算法的目的都建立一个优化网络模型，主要是用过优化算法对损失函数进行优化，从而建立一个最优的网络模型。优化算法是一种数学方法，其主要思想是处理在给定的数据以及约束条件下，使现有结果达到最优解。常见的优化函数包括有梯度下降法、自适应学习率算法、RMSProp 算法等等。

## （4）梯度下降

梯度下降算法在深度神经网络模型中表现出良好的优化能力且便于设计。梯度下降算法的主要思想为当损失函数是凸函数时，其得到的结果时全局最优解。梯度下降法主要是以目标当前所处位置的最快下降方向为优化方向，故梯度下降法也成为最快下降法。梯度下降法越接近最优解时，其搜索步长越小，优化速度将会减慢。因此梯度下降法具有靠近最优解时优化速度减慢、可能会呈现之字形下降等缺点。在深度神经网络模型中，梯度下降法主要分为批量梯度下降法、随机梯度下降法、小批量随机梯度下降法等方法。

批量梯度下降法是以全部训练样本进行迭代，每次更新所有训练样本的损失函数，使得最后批量下降法求的解为全局最优解，但批量梯度下降法随着样本数量的增加，

效率会呈现明显降低的趋势且会出现无法找到最优解的情况；随机梯度下降法是以每个样本数据进行迭代，虽然不是每次优化的方向都是全局最优方向，但是其整体趋势时以全局最优解方向进行优化，在样本数量较大时，其运算速度明显优于批量梯度下降法。

### （5）正则化

神经网络模型中一个核心问题就是防止过拟合，即模型不仅需要在训练数据集上表现出相应的模拟能力，在测试数据集上仍然能够表现良好。正则化算法即是被用来减少网络模型在测试数据集上的误差的算法。神经网络模型由于其强大的拟合能力，经常在出现过拟合问题，故必须需要正则化算法对其进行优化。常见的正则化算法包括 Dropout 算法、L2 正则化算法等。Dropout 正则化主要是在神经网络中关闭相应的隐含层神经元，降低其拟合能力，防止其出现过拟合现象，因为 Dropout 正则化是随机关闭每层隐含层一定数量的神经元，故在没有加深网络模型的前提下使得神经网络具备更加复杂的网络结构，使得神经网络可以得到更为良好的模拟效果。

#### 4.1.2 神经网络算法简介

神经网络模型是依据对动物神经元的学习与研究，模拟其互相连接、自组织特性以及非线性特性而构建的算法。数理逻辑学家 Pitts 在 1943 年提出了具有开创意义的第一个神经网络模型——MP 模型，MP 模型为神经网络模型提供了相应的算法支撑以及借鉴意义。数学家 Rosenblatt 以 MP 模型为基础，提出了一种具备学习能力的单层感知机模型，第一次将众多学者的目光集中于神经网络模型之上，但是单层感知器网络模型在处理线性不可分问题时遇到了瓶颈。直至 Rumelhart 等人提出了一种自学习前馈反向传播神经网络模型即是 BP 网络模型，在处理线性不可分问题时取得了重大突破。

深度学习作为近年来快速发展的领域因其在分类与预测领域的良好表现受到国内外众多学者的关注，深度学习算法在特征提取和建模上相较于机器学习算法具有明显的优势。其能够从客观样本数据中挖掘抽象的客观规律，且这些规律在测试数据集上表现出良好的泛化能力以及对具备缺失值的数据具有优秀的鲁棒性。随着大数据时代的到来以及计算机处理能力的剧增，深度学习算法在行人检测、图像分类、地物提



取和语音识别等领域表现出优秀的应用能力。深度学习是以传统 BP 神经网络为基础，具有多层非线性的层级学习模型，深层神经网络是目前深度学习算法的主要形式。深度神经网络具有局部连接、权值共享等特性，可以有效降低网络模型的复杂度，减少模型的计算时间以及提高模型的模拟精度，使得深度神经网络模型在处理高维数据时表现出良好的分类与识别能力，并对具有缺失值的数据有较强的忍耐性，且目前深度神经网络模型设计相较于其他深度学习模型易于设计以及便于优化。

#### 4.1.3 Keras 开发模块简介

Keras 是基于 Python 开发语言的第三方深度学习模块，Keras 与现在国际上主流的深度学习模块 Tensorflow 不同，由纯 Python 语言编译而成，并且其能够与深度学习模块 Tensorflow、Theano 联合工作。Keras 将 Tensorflow、Theano 高度模块化，不需要使用者具备高超的软件编程能力，便于网络模型的构建与调试。Keras 是能够快速将研究者的想法转换为深度学习模型，并快速进行实验。Keras 模块具有以下优点：

（1）迅速设计研究者心中的深度学习模型。Keras 高度模块化，可以快速构建一个深度神经网络，包括其网络层、损失函数、优化函数、激活函数、正则化方法等，其均提供相应的模块供开发人员使用。只需要将其简单组合即可完成一个复杂的网络模型。

（2）丰富的扩展能力，Keras 不仅能够使用其提供的相关参数与算法，用户可以调整与自定义相关算法。用户只需要仿照示例程序即可编写适用于研究内容的新函数。

（3）支持 CNN 网络模型与 RNN 网络模型，且可以将两种网络模型进行无缝对接。

（4）支持 GPU 并行运算，可以极大的减少程序运行时间。

（5）Keras 以开发人员为核心，注重开发人员的用户体验，极大的减少开发人员的工作量，并提供优秀的错误反馈机制以帮助开发人员快速改进相关代码。Keras 具备相应易用性的同时不会降低其灵活性，与 TensorFlow 相同，Keras 可以实现绝大多数的深度学习网络模型。

## 4.2 基于深度学习的土地利用模型构建

目前，RF-BDI 决策模型在选取影响因素方面具有一定的优势，例如在构建 RF-BDI 农户决策模型时，在训练完成后可以依据特征向量的贡献度对其进行排序依次选择最优向量，但 RF-BDI 模型难以精准模拟农户的随机种植行为，虽然随机森林具备一定的自学习能力但仍不足以对所有农户决策做出相应的模拟；DNN 具备更强

的学习能力,可以更好地模拟农户 Agent 决策行为,尝试基于深度神经网络构建土地利用变化模型。本章在上一章构建的 RF-BDI 农户决策模型基础上,选取的特征向量,并选择适宜于农户决策的激活函数、损失函数、优化函数和正则化技术,构建基于深度神经网络模型的微观主体土地利用行为决策模型,并以陕西省米脂县高渠乡为样本数据,对其 2016 年和 2017 年农户作物种植情况进行模拟和检验,以确定所构建模型的准确性和可行性。

在影响参数选取上,本文主要是基于团队前期构建的 CBDI、CRBDI 等土地利用变化模型,选取坡度、坡向、高程、地形起伏度、距离道路距离,以及 Ability 参数作为模型的特征向量。其中坡度、坡向、高程、地形起伏度、距离道路距离为影响农户决策的自然条件因素,Ability 参数为农户种植能力、市场价值趋向以及种植规范的集合,为了加快神经网络的学习速度,对输入的特征向量进行 Z-Score 标准化,公式为:

$$x_i^* = \frac{x_i - \mu}{\delta} \quad (4.1)$$

其中,  $x_i^*$  表示均一化值;  $x_i$  表示样本值;  $\mu$  表示样本数据的均值;  $\delta$  表示样本数据的标准差。

农户 Agent 土地利用行为的直接表现形式为土地利用类型的变化,将研究区 2016 年土地利用类型作为神经网络中输出神经元的特征集合。为了方便神经网络的训练,对土地利用类型进行编号,但即使对土地利用类型编号之后也不能直接用于训练神经网络,神经网络默认数字数据是连续的并且是有序的,但对于土地利用类型而言,是随机分配的。本文采取独热编码 (One-Hot Encoding) 对其标准化,独热编码是利用多个状态寄存器对每个样本数据进行独立编码,每个样本都有且仅有一个独立的寄存器位。即对于一个具有 M 个 N 类的特征集合,经过独热编码标准化后将其转为 M\*N 的二维特征集合。

本文用于构建 DNN 模型的数据主要来自研究团队长期实地调研的农户数据,通过 Arcgis 软件将其与对应地块相关联,并结合 Arcgis 中坡度分析、近邻分析等空间分析功能获取相关影响因素,最后将其保存为.xls 文件用于训练深度神经网络。

本文深度神经网络模型采用 Python 语言,使用数据分析包 Pandas 以及深度学习开源框架 Keras 实现的。通过 Keras 构建 DNN 模型,首先需要定义一个基础网络结

构，主要包括输入输出神经元、激活函数、损失函数、优化函数等结构；然后根据实际表现深化网络结构。对于输入神经元数量，主要是根据影响农户决策的因素而定；输出神经元个数则与土地利用类型数目相同。在 Keras 中为开发者提供了常见的激活函数、优化函数以及损失函数。

神经网络中激活函数的选择至关重要，如果不采用激活函数，无论网络有多少层，输出都是输入的线性组合。因此，面对行为具有复杂性的农户 Agent 决策，本文选用 Softmax 函数作为激活函数以处理多分类问题，具体为：

$$\delta(x)_j^L = \frac{e^{z_j^L}}{\sum_{k=1} e^{z_k^L}} \quad (4.2)$$

其中， $\delta(x)_j^L$  表示每个类别的概率； $z_j^L$  表示神经元值。

Softmax 函数可以把一个 N 维的向量映射为一个出现概率的 K 维集合，这个 K 维集合的和始终为 1，如果将 K 维集合看做一个概率分布，输出层的分类结果就是每个分类标签出现的概率。农户 Agent 决策更像是一种基于概率的决策行为，选取 Softmax 函数作为激活函数可以模拟的农户 Agent 决策复杂性，使网络的输出值与农户 Agent 决策结果更为接近。

在选取 Softmax 函数作为激活函数时，一般选择 log-likelihood 函数作为损失函数（Loss Function）计算测试集中实际值与预测值的偏离程度，log-likelihood 函数的定义为：

$$C = -\ln a_y^L \quad (4.3)$$

其中， $a_y^L$  表示神经元 y 对应的预测概率，概率 a 越接近 1，损失函数 C 越接近 0；反之，C 趋近于极大。

在 DNN 中，梯度下降是一个重要算法，主要是用于神经网络中的权重更新和偏向更新，通过最小化损失函数更新模型参数，使模型收敛。本文选择小批量随机梯度下降算法，每次选取 m 个训练样本进行迭代，进行一次更新。小批量梯度下降算法可以减少参数更新的波动，收敛的更快更稳定。小批量梯度下降算法具体为：

$$\theta_i := \theta_i - \alpha \sum_{j=t}^{t+m-1} (h_0(x_0^j, x_1^j, \dots, x_n^j) - y_i) x_i^j \quad (4.4)$$

其中， $\theta_i$  为模型参数； $x_i$  表示每个样本的 i 个特征值； $\alpha$  表示步长； $h_0$  表示模型的假设函数。

---

因此，本文深度神经网络模型通过以下方式构建：

```
Model=Sequential()
```

```
Model.add(Dense(N_Hidden,input_dim=vector_class))
```

```
Model.add(Activation('softmax'))
```

```
Model.compile(loss='categorical_crossentropy',optimizer=sgd,metrics=['accuracy'])
```

本文采用研究区实地调研的农户 Agent 决策数据共 7000 多条数据，选取其中 4000 条数据作为训练集。训练集的数量不足会导致训练得到的模型不能估计出农户 Agent 决策规则，产生严重的过拟合。为了避免过拟合的产生，本文采用针对神经网络所提出的 Dropout 正则化技术，将神经网络结构中的隐藏节点按照给定的概率进行丢弃。Dropout 正则化在丢弃的过程中采取随机丢弃原则，经过交叉验证，隐藏节点的 Dropout 率为 0.5 时效果最好，对于一个有 N 个节点的神经网络在经过 Dropout 正则化后，即变为  $2^n$  个模型的集合。

在网络中加入正则化技术可以通过以下方式添加：

```
Model.add(Dropout(0.5))
```

最后根据模型表现情况增加网络层数以及神经元个数，或者尝试使用其他激活函数、损失函数、优化函数以构建出最合适的网络结构。

## 4.3 结果分析

本章以陕西省米脂县高渠乡为例，通过两因素、多因素和实际转化等 3 种情景，以研究区 2016 年实际土地利用变化数据训练模型，首先基于情景模拟方式分析深度神经网络模型用于模拟土地利用变化的可行性，最后对比 RF-BDI 模型与 DNN 模型，分析两者之间的差异。其中本文模拟精度检验方法是以模型预测图与当年卫星影像解译数据进行对比。

### 4.3.1 深度神经网络模型结果分析

研究区农户土地利用类型主要有：玉米、果园、红葱、土豆、杂粮等，其土地利用行为变化主要发生在土豆和杂粮两种耕地类型上，传统 BDI 模型主要选取地形起伏度和距离乡村主要道路距离作为主要影响因素建立 BDI 决策规则。同时为了简化规则，将地形起伏度划分为伏度小、伏度中、伏度大 3 类，分别用 1、2、3 表示，距离乡村主要道路距离划分为距离近、距离中、距离远 3 类，分别用 1、2、3 表示。为

表达两种因素的综合影响，采用如下规则进行表达：个位数代表地形起伏度类型，十位数代表距道路距离类型。例如 11 和 32 分别农户地块距道路距离近伏度小的条件和距道路远起伏度中的条件。

依据研究区作物种植实际情况构建以下规则：土豆在自然条件 13、23、31 条件下保持不变，下一年作物仍然种植土豆；在不同于这 3 类自然条件下，下一年作物由土豆转化为杂粮。杂粮在 11、21、31 条件下，即地形起伏度小的条件下，下一年作物由杂粮转化为土豆；在不同于 11、21、31 情况下，种植作物保持杂粮不变。玉米、果园、红葱等 3 种土地利用类型默认保持不变。依据上述规则，可将农户 Agent 土地利用行为转换为二分类问题，0 为土豆，1 为杂粮，若只考虑地形起伏度和距离农村道路距离构建模型，模拟结果如表 4 所示。

表 4 两因素精度对比（%）

Tab.4 Comparison of binary accuracy

准确率	BDI 模型	BP 神经网络 (3 Layers)	DNN (5 Layers)
二分类精度	65.67	63.21	64.42
总体精度	68.51	67.05	67.87

本文的二分类情景是默认除了土豆和杂粮其他土地利用类型不发生转化，即只考虑土豆和杂粮的转化，总体精度即所有土地利用类型转化精度。由表 4 可以看出：在只考虑地形起伏度和距离道路距离的情况下，BP 神经网络表现比 BDI 模型差，模拟精度下降了 2.46%，总体精度下降了 1.46%；同时可以看出：DNN 比 BP 神经网络增加两层隐含层，具有更好的学习能力，总体精度略好于 BP 神经网络，但仍低于 BDI 模型的总体精度 0.64%。因此，在两因素情景下，DNN 没有表现出其优异的模拟能力。为了检验其具体原因，下面进行多因素情景下的土地利用行为模拟。

BDI 模型的转化规则是由研究者人为设定，主要是依据当地的实地情况和研究者的经验确定 BDI 模型的决策规则，由此造成 BDI 模型转换规则设定过于刚性。故本文把 BDI 模型中坡度、坡向、高程、距离农村道路距离、距离居民点距离、距离公路距离等影响因素同时放入深度神经网络中训练模型，模拟结果如表 5 所示。

表 5 多因素精度对比 (%)

Tab.5 Comparison of multifactor accuracy

准确率	BP 神经网络 (3 Layers)	DNN (5 Layers)
多分类精度	71.22	73.37
总体精度	73.57	74.98

由表 5 可以看出：在综合考虑坡度、坡向、高程、距离乡村道路距离、距离居民点距离、距离公路距离等特征后，在土豆和杂粮转化精度上，BP 神经网络比传统 BDI 模型提升 5.55%，DNN 则提升了 7.70%；在总体精度上，BP 神经网络和 DNN 比传统 BDI 模型分别提升 5.06%、6.47%。由此可见，在仅考虑土豆和杂粮转换情景的条件下，综合考虑自然和人文因素后，神经网络训练的模型的模拟精度均高于传统 BDI 模型。

BDI 模型中为了简化规则，只考虑土豆和杂粮的互相转化，但在实际调研中发现，玉米、果园、红葱会和土豆和杂粮间也可相互转化。因此，本文根据实际情况，将玉米、果园、红葱、土豆、杂粮间的转化状况均放入 DNN 中训练模型；为了对比分析不同层 DNN 模型的模拟效果，本文设置 10 层 DNN 模型，模拟结果如表 6 所示。

表 6 深度神经网络精度对比 (%)

Tab.6 Comparison of Deep Neural Network accuracy

网络层数	训练集精度	测试集精度
5	75.61	74.02
6	75.98	72.98
7	77.41	75.20
8	81.23	79.83
9	79.54	77.21
10	78.69	76.08

在深度神经网络模拟时，首先仅调整隐藏层层数。每个隐藏层神经元均为 128，Dropout 参数为 0.5，优化函数选用小批量随机梯度下降算法，Batch 为 25，执行迭代次数 (epochs) 为 10000。由表 6 可知，深度神经网络模拟效果并不是随隐含层层数增加越来越好，当层数为 8 层时，训练出来网络模拟效果最好，比 BDI 模型预测精度提高了 17.32%。即使表现较差的 5 层神经网络亦比传统 BDI 模型预测精度提升 5.51%。其次，将神经网络层数设置为 8 层，调整神经元数量，当神经元数量为 16 时，精度仅有 51.3%；当神经元数量为 32 时，精度快速提高到 68.5%；当神经元数量提升为 256 时，精度提升到 85.1%，之后随着神经元数量的增加精度仍会小幅度增加，增加

幅度不断减小，但计算时间却明显延长（表 7）。综合考虑计算机性能以及精度要求，故本文选取 256 作为神经元数量。结果表明采用深度神经网络模型，可以更好的模拟农户 Agent 决策，有效提升预测精度。

表 7 神经元数量对比（%）

Table.7 Comparison of the count of Neurons

神经元数量	训练集精度	测试集精度	时间/Min
16	52.36	51.27	5
32	69.77	68.49	17
64	79.21	77.33	20
128	81.23	79.83	35
256	81.91	80.12	57
512	81.95	80.34	104
1024	81.93	80.41	179

利用构建的 DNN 模型预测高渠乡 2016 年土地利用类型，并与高渠乡 2016 年实际土地利用类型对比，生成高渠乡 2016 年土地利用类型对比图（图 8）。

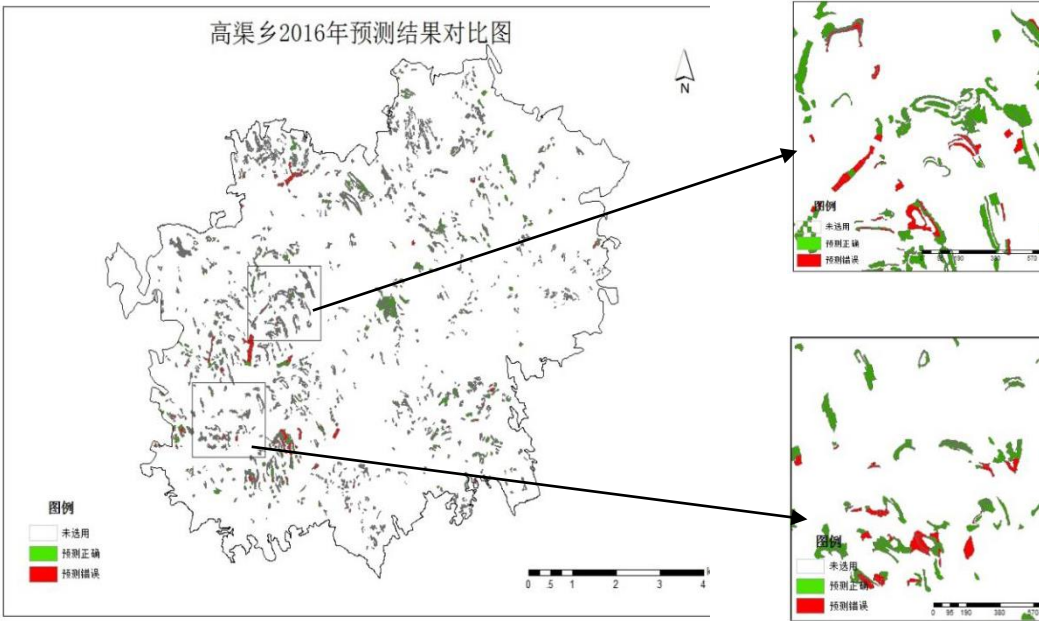


图 8 高渠乡 2016 年预测结果对比图

Fig.8 The comparison of Gaoqu Commune of Mizhi County

图 8 显示，DNN 模型预测正确率为 85%。预测错误主要来源于玉米，约占全部预测错误地块的 40%，主要集中于距离道路距离较近并且地形起伏度较大的区域。其他错误类型主要来源于葱和杂粮两种类型，分别占 27%与 24%。其中红葱的错误地

块主要集中于地形起伏度适中且距离道路距离较近的区域，杂粮的错误地块主要集中于距离道路距离适中且地形起伏度较小的区域。最后，预测土豆的错误地块约占 7%，主要集中于距离道路距离较远且地形起伏度较小的区域。结果显示，DNN 模型受道路距离因素影响较大，由于农户决策经常根据其自身种植经验调整策略且具有独立性，部分农户会在距离道路距离较近的区域种植较为多样的种植作物，从而使模型产生预测错误，但 DNN 模型仍可以较为准确的预测农户土地利用行为。

#### 4.3.2 RF-BDI 模型与 DNN 模型对比分析

以隐含层数为 8 层且每层的神经元数量为 256 的深度神经网络模型与 RF-BDI 模型进行对比分析，以 2016 年陕西省米脂县高渠乡为例，两种模型模拟结果如下：

表 8 2016 年 DNN 模型与 RF-BDI 模型精度对比（%）

Tab.8 Comparison of DNN model and RF-BDI model accuracy in 2016

	RF-BDI 模型	DNN 模型
土豆	82.1	87.4
杂粮	79.9	85.4
玉米	80.4	81.3
果树	81.5	85.9
红葱	79.2	84.6
其他	78.3	87.2

由上表可知，RF-BDI 模型的整体模拟精度为 80.2%，DNN 模型的整体模拟精度为 85.3%，DNN 模型相较于 RF-BDI 模型整体模拟精度提升约为 5%。其中提升最大的是其他地块，提升约为 9%，由此可见，DNN 模型对农户的随机种植行为具有更好的模拟效果，可以实时调整农户的决策规则。在现有的数据下，DNN 模型对其他地块的模拟效果也均高于 RF-BDI 模型，除玉米类型，其他类型提升均为 5%，玉米类型的模拟效果较差，但也提升 1% 模拟精度。故 DNN 模型应用于乡村土地利用变化模拟具有一定的可行性。

深度神经网络模型和 RF-BDI 模型对高渠乡受政策影响较大年份 2017 年模拟结果如表 9 所示，深度神经网络模型比 RF-BDI 模型总体模拟准确率约高 6%，其中玉米、杂粮、土豆、红葱等 4 种土地利用类型与 2016 年模拟情形相似，但对于其他类型以及果树的模拟效果，深度神经网络模型模拟结果略高于 RF-BDI 模型，故深度神经网络模型对农户受政策驱动将其他土地利用类型转变为果树的行为有较强的拟合



能力，且对农户随机种植行为有较强的学习能力。

表 9 2017 年 DNN 模型与 RF-BDI 模型精度对比 (%)

Tab.9 Comparison of DNN model and RF-BDI model accuracy in 2017

土地利用类型	深度神经网络模型	RF-BDI 模型
玉米	85.5	77.1
土豆	82.9	80.6
杂粮	85.4	80.3
红葱	82.6	79.8
果树	79.1	65.4
其他作物类型	84.6	69.4

综上所述，在模拟效果上，DNN 模型比 RF-BDI 模型表现得更为出色，但由于 DNN 模型属于黑箱模型的一种，只能设计其网络结构与相应参数，不利于查询每种影响因素对此次模拟过程的贡献度，因此，在机理解释上 RF-BDI 模型比 DNN 模型表现的更为直观，其提供变量重要性度量功能有利于解释土地利用变化的影响机理，且 RF-BDI 模型的转换规则可以根据人为经验对其进行调整，而 DNN 模型无法调整其转换规则。

#### 4.4 本章小结

本文提出了一种通过深度神经网络构建农户 Agent 决策模型的方法，分析农户 Agent 土地利用行为及其变化，首次将深度神经网络用于农户视角下土地利用变化模拟。由于农户 Agent 决策是一种基于概率的决策行为，本文选取 Softmax 函数作为激活函数，可以更好地模拟农户决策。为了避免过拟合现象，本文 DNN 模型中引入 Dropout 正则化技术以减少训练集不足的影响。综合考虑模拟精度与模拟效率确定神经网络的层数与神经元数量，最终基于 Python 平台的 Keras 开源模块实现 DNN 模型。通过两因素、多因素和实际转化等 3 种情景对比 BDI 决策模型与 DNN 模型的优劣，在特征向量和数据量较少时，DNN 模型无法准确学习 Agent 决策行为，模拟结果略低于 BDI 决策模型，随着特征向量的增多与数据量体量的增大，DNN 模型模拟 Agent 决策更为合理，其模拟精度约为 85%。结果表明，深度神经网络用于构建农户 Agent 决策是一种可行、有效的模拟方法。

随着研究区扩大，复杂多样的农户 Agent 属性给 BDI 模型中决策规则的设定带来了严峻挑战，同时深度神经网络中高维数据处理需要的计算能力仍需要改善，特征工程在深度神经网络模型构建中就显得尤为重要。如何结合 BDI 模型选取最优特征

---

向量为 DNN 模型提高模拟效率显得尤为重要。此外，以现有数据为基础，如何有效利用 RF-BDI 模型在机理解释上的优点和 DNN 模型在模拟效果上的优点，构建既能揭示土地系统的变化机制，又有较高准确率的模型是作者及今后进一步努力的方向。

---

## 第五章 结论与讨论

### 5.1 结论

本文以典型生态脆弱区米脂县为例，利用 PRA 和传统农户调查获取所需数据，结合机器学习算法、深度学习算法以及传统土地利用变化模型，对比分析 3 种方法的优劣，主要进行以下 2 个方面的工作：（1）人为设定规则构建 BDI 模型，并将该模型与随机森林算法进行耦合，构建 RF-BDI 模型，运用随机森林提取农户决策的变量重要性以及挖掘与完善农户决策行为规则（2）在 BDI 框架的指导下，运用随机森林算法选取最优特征向量，利用深度神经网络算法独立挖掘农户决策规则并构建土地利用变化模拟模型。在上述分析的基础上，得出以下结论：

（1）随机森林算法与 BDI 模型结合可以有效揭示农户有限理性决策行为及其变化机理。以陕西省米脂县高渠乡为例，结果显示 RF-BDI 模型对传统 BDI 模型决策行为进行修正后，在没有明显增大计算量的基础上模拟精度提高了 14%。

（2）相比 BDI 模型和 RF 模型，RF-BDI 模型的转化规则的设置更为合理。传统 BDI 模型是人为基于经验确定农户的决策规则，此规则设定较为简单，且过于刚性。随机森林算法虽可以“挖掘”农户土地利用行为规则，但挖掘规则过于理性，无法反应农户的随机种植行为。RF-BDI 模型通过将随机森林挖掘规则与基于经验的规则进行相互印证，可以有效消除农户随机种植行为带来的误差，提高模型模拟精度。

（3）虽然 RF-BDI 模型可以较好的模拟农户种植行为，但仍有约为 20% 的误差，深度学习相较于机器学习具备更好的挖掘能力与模拟能力，本文以深度神经网络模型为例，对比深度神经网络模型与 RF-BDI 模型模拟情况。以 Keras 模块开发深度神经网络模型，设计与调整网络结构，以陕西省米脂县高渠乡为数据源。在未设置经验规则的前提下，深度神经网络模型独立提取农户有限理性决策规则，模拟与预测高渠乡土地利用变化并与实际土地利用变化进行对比，其模型精度为 85.2%，相较于 RF-BDI 模型，深度神经网络模型模拟精度提高约为 5%。该模型可以有效模拟农户随机种植行为，并预测其未来种植倾向，揭示该区域未来土地利用变化情形。

### 5.2 讨论

随着地理大数据的提出，越来越多的学者开始将目光转移到深度学习之上，但地

---

理数据时常与人相关，具备一定的随机性。本文尝试用机器学习与深度学习算法模拟土地利用变化仍存在以下改进之处：

（1）完备原始数据的获取，尤其是较为全面人文因素的获取。本文用于模拟农户土地利用变化的数据除需要自然地理数据外，仍需要大量的人文数据，人文数据的获取通常通过 **PRA** 与问卷调查法相结合。本文设置问卷时，采取基于经验与实际情形结合的设置方式，但仍会受到人文因素的影响，导致问卷数据不准确或者问卷数据不全面等因素。如何获取更为全面与客观的人文因素，是下一步需要思考的问题之一。

（2）算法选择与参数设置。在机器学习算法中，本文选取较为常用的随机森林算法，其模拟结果取得了较大进步，但是否有其他机器学习算法更为简便或可以更为准确的模拟土地利用变化仍需要进一步研究。其次，在随机森林算法实现过程中，首先为了提高运行速度以及模拟精度，基于随机森林选取的变量重要性剔除了部分影响因素，但其剔除变量的数目以及随机森林树木的多少需要反复试验进行确定，如何精确获取该参数需要进一步尝试。

（3）深度神经网络网络模型的设置。深度神经网络其网络模型灵活多变，虽然深度神经网络可以自动模拟与预测土地利用变化，不需要额外的设置转换规则。但其需要研究者根据其模拟情况调整网络结构，主要包括神经元数量、隐含层数目、激活函数、优化函数、损失函数等。其参数设置是否准确直接影响深度神经网络模型的模拟效果。如何设置更为合理的网络结构以及采用多网络耦合的方式更为准确的模拟与预测土地利用变化情形是接下来的主要研究任务之一。

---

## 参考文献

- [1] 田光进, 邬建国. 基于智能体模型的土地利用动态模拟研究进展[J]. 生态学报, 2008, 28(9): 4451-4459.
- [2] Xu Q L, Yang K, Wang G L, et al.. Agent-based modeling and simulations of land-use and land-cover change according to ant colony optimization: a case study of the Erhai Lake Basin, China[J]. Natural Hazards, 2015, 75(1): 95-118.
- [3] 余强毅, 吴文斌, 唐华俊, 等. 基于农户行为的农作物空间格局变化模拟模型架构[J]. 中国农业科学,
- [4] 陈凯, 刘凯, 柳林, 等. 基于随机森林的元胞自动机城市扩展模拟: 以佛山市为例[J]. 地理科学进展,
- [5] 陈海, 梁小英, 高海东, 等. Multi-Agent System 模型在土地利用/覆盖变化中的研究进展[J]. 自然资源学报, 2008. 23 (2): 345-352.
- [6] 余强毅, 吴文斌, 唐华俊, 等. 复杂系统理论与 Agent 模型在土地变化科学中的研究进展[J]. 地理学报, 2011, 66(11): 1518-1530.
- [7] 陈海, 梁小英, 王国义, 等. 基于过程的农户土地利用行为模型的设计与模拟研究[J]. 自然资源学报, 2014, 29(6): 1076-1089.
- [8] 余强毅, 吴文斌, 杨鹏, 等. Agent 农业土地变化模型研究进展[J]. 生态学报, 2013, 33(6): 1690-1700[9]王艳妮, 陈海, 宋世雄, 等. 基于 CR-BDI 模型的农户作物种植行为模拟: 以陕西省米脂县姜兴庄为例[J]. 地理科学进展, 2016. 35(10): 1258-1268.
- [10] 李少英, 刘小平, 黎夏, 等. 土地利用变化模拟模型及应用研究进展[J]. 遥感学报, 2017, 21(3): 329-340.
- [11] 张延伟, 裴颖, 葛全胜. 基于 BDI 决策的居住空间宜居性分析: 以大连沙河口区为例[J]. 地理研究, 2018, 35(12): 2227-2237.
- [12] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(06): 1229-1251.
- [13] 侯越. 基于改进 T-S 模糊神经网络的交通流量预测[J]. 计算机科学与探索, 2019, (1): 121-126.
- [14] 党宇, 张继贤, 邓喀中, 等. 基于深度学习 AlexNet 的遥感影像地表覆盖分类

---

评价研究[J]. 地球信息科学学报, 2018. (11):1530-1537.[15]郭宁宁, 盛业华, 黄宝群, 等. 基于人工神经网络的多特征因子路网匹配算法[J]. 地球信息科学学报, 2016, (09): 1153-1159.

[16] Hinton G, Deng L, Yu D, et al. Deep neural networks for acoustic modeling in speech recognition: the shared views of four research groups. IEEE Signal Processing Magazine, 2012, 29(6): 82-97.

[17] Goodfellow I, Bengio Y, Courville A. Deep Learning[M]. Cambridge, UK: MIT Press, 2018.

[18] Srivastava N, Hinton G, Krizhevsky A, et al.. Dropout: A simple way to prevent neural networks from overfitting[J]. The Journal of Machine Learning Research, 2014, 15(1): 1929-1958.

[19] 王瑞波, 李济洪, 李国臣, 等. 基于 Dropout 正则化的汉语框架语义角色识别[J]. 中文信息学报, 2017, 31(1): 147-154.

[20] 陈海,梁小英,王国义,等.基于过程的农户土地利用行为模型的设计与模拟研究[J].自然资源学报,2014, 29(6):1076-1089.

[21] 陈海,王涛,梁小英,等.基于 MAS 的农户土地利用模型构建与模拟:以陕西省米脂县孟岔村为例[J].地理学报,2009, 64(12):1448-1456.

[22] 余强毅,吴文斌,唐华俊,等.复杂系统理论与 Agent 模型在土地变化科学中的研究进展[J].地理学报,2011, 66(11):1518-1530.

[23] 黎夏,刘小平.基于案例推理的元胞自动机及大区域城市演变模拟[J].地理学报.2007, 10:1097-1109.

[24] 唐华俊,吴文斌,杨鹏,等.土地利用/土地覆被变化(LUCC)模型研究进展[J].地理学报,2009, 64(4): 456-468.

[25] 杨俊,裴颖,席建超,等. 基于 BDI 决策的 MAS-CA 模型黄海海滨城镇格局模拟研究——以大连金石滩为例[J].地理科学,2016,3:410-416.

[26] 刘淑燕,余新晓,李庆云,等.基于 CA-Markov 模型的黄土丘陵区土地利用变化[J].农业工程学报,2010, 26(11):297-303.

[27] 吴文斌,杨鹏,柴崎亮介等.基于 Agent 的土地利用/土地覆盖变化模型的研究进展[J].地理科学,2007,27(4):573-578.

[28] 梁小英,刘俊新.农户土地利用决策对农业景观格局的影响研究:以陕西省米

---

脂县孟岔村为例[J].自然资源学报,2010, 25(9):1489-1495.

[29]曹阳,甄峰. 基于智慧城市的可持续城市空间发展模型总体架构[J]. 地理科学进展, 2015,34(4): 430–437.

[30]胡茂桂,傅晓阳,张树清,宋开山,王宗明. 基于元胞自动机的莫莫格湿地土地覆被预测模拟[J]. 资源科学, 2007,29(2): 142–148

[31]Clarke K C, Hoppen S and Gaydos L. A self-modifying cellular automaton model of historical urbanization in the San Francisco Bay area[J]. Environment and Planning B: Planning and Design,1997,24(2): 247–261

[32]康停军,张新长,赵元,王海鹰,张维. 基于多智能体的城市人口分布模型[J]. 地理科学,2012, 32(7):790–797

[33]刘小平,黎夏,陈逸敏,刘涛,李少英. 基于多智能体的居住区位空间选择模型[J]. 地理学报,2010, 65(6): 695–707

[34]张亦汉,黎夏,刘小平,乔纪纲,何执兼. 耦合遥感观测和元胞自动机的城市扩张模拟[J]. 遥感学报, 2013,17(4): 872–886

[35]周淑丽,陶海燕,卓莉. 基于矢量的城市扩张多智能体模拟——以广州市番禺区为例[J]. 地理科学进展, 2014,33(2): 202–210

[36]沈润平,郭佳,张婧娴,李洛晞. 基于随机森林的遥感干旱监测模型的构建[J]. 地球信息科学学报,2017,19(01):125-133.

[37]杨珺雯,张锦水,朱秀芳,谢登峰,袁周米琪. 随机森林在高光谱遥感数据中降维与分类的应用[J]. 北京师范大学学报(自然科学版),2018,51(S1):82-88.

[38]陈凯,刘凯,柳林,朱远辉. 基于随机森林的元胞自动机城市扩展模拟——以佛山市为例[J]. 地理科学进展,2015,34(08):937-946.

[39]李亭,田原,郭伦,刘亮. 基于随机森林方法的滑坡灾害危险性区划[J]. 地理与地理信息科学,2014,30(06):25-30+2.

[40]张雷,王琳琳,张旭东,刘世荣,孙鹏森,王同立. 随机森林算法基本思想及其在生态学中的应用——以云南松分布模拟为例[J]. 生态学报,2014,34(03):650-659.

[41]梁小英. 生态脆弱区宏观土地利用功能变化的微观驱动机制研究[D]. 西北大学,2018.

[42]姚登举,杨静,詹晓娟. 基于随机森林的特征选择算法[J]. 吉林大学学报(工学

---

版),2014,44(01):137-141.

[43]欧定华,夏建国,欧晓芳.基于 GIS 和 RBF 的城郊区生态安全评价及变化趋势预测——以成都市龙泉驿区为例[J].地理与地理信息科学,2017,33(01):49-58.

[44]曹洪洋,王禹,满兵.基于 GIS 的区域群发性降雨型滑坡时空预报研究[J].地理与地理信息科学,2015,31(01):106-109+124.

[45]周飞燕,金林鹏,董军.卷积神经网络研究综述[J].计算机学报,2018,40(06):1229-1251.

[46]焦李成,杨淑媛,刘芳,王士刚,冯志玺.神经网络七十年:回顾与展望[J].计算机学报,2016,39(08):1697-1716.

[47]郭丽丽,丁世飞.深度学习研究进展[J].计算机科学,2015,42(05):28-33.

[48]刘智斌,曾晓勤,刘惠义,储荣.基于 BP 神经网络的双层启发式强化学习方法[J].计算机研究与发展,2018,52(03):579-587.

[49]李东,周可法,孙卫东,王金林,于浩,刘慧.BP 神经网络和 SVM 在矿山环境评价中的应用分析[J].干旱区地理,2015,38(01):128-134.

[50]程学旗,靳小龙,王元卓,郭嘉丰,张铁赢,李国杰.大数据系统和分析技术综述[J].软件学报,2014,25(09):1889-1908.

[51]杨雅辉,黄海珍,沈晴霓,吴中海,张英.基于增量式 GHSOM 神经网络模型的入侵检测研究[J].计算机学报,2014,37(05):1216-1224.

[52]刘建伟,刘媛,罗雄麟.深度学习研究进展[J].计算机应用研究,2014,31(07):1921-1930+1942.

[53]肖锦成,欧维新,符海月.基于 BP 神经网络与 ETM+遥感数据的盐城滨海自然湿地覆被分类[J].生态学报,2013,33(23):7496-7504.

[54]余凯,贾磊,陈雨强,徐伟.深度学习的昨天、今天和明天[J].计算机研究与发展,2013,50(09):1799-1804.

[55]孙志军,薛磊,许阳明,王正.深度学习研究综述[J].计算机应用研究,2012,29(08):2806-2810.

[56]Y. Bengio, N. Boulanger-Lewandowski, and R. Pascanu. Advances in optimizing recurrent networks. In proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing, pages 8624--8628, 2013.



- 
- [57]J. Bergstra and Y. Bengio. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, 13(12):281--305, 2012.
- [58]A. Choromanska, M. Henaff, M. Mathieu, G. B. Arous, and Y. LeCun. The loss surfaces of multilayer networks. In *proceedings of the International Conference on Artificial Intelligence and Statistics*, pages 192--204, 2015.
- [59]P. Domingos. A few useful things to know about machine learning. *Communications of the ACM*, 55(10):78--87, 2012.
- [60]J. Duchi, E. Hazan, and Y. Singer. Adaptive subgradient methods for online learning and stochastic optimization. *Journal of Machine Learning Research*, 12(12):2121--2159, 2011.
- [61]I. Goodfellow, Y. Bengio, and A. Courville. *Deep learning*. MIT press, 2016.
- [62]K. He, X. Zhang, S. Ren, and J. Sun. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In *proceedings of the IEEE International Conference on Computer Vision*, pages 1026--1034, 2015.
- [63]S. Ioffe and C. Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *proceedings of the International Conference on Machine Learning*, pages 448-456, 2018.
- [64]D. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [65]F.-F. Li, A. Karpathy, and J. Johnson. CS231n: Convolutional Neural Networks for Visual Recognition. Stanford, 2016.
- [66]F.-F. Li, J. Johnson, and S. Yeung. CS231n: Convolutional Neural Networks for Visual Recognition. Stanford, 2017.
- [67]A. Ng. Improving deep neural networks: Hyperparameter tuning, regularization and optimization. *deeplearning.ai*.
- [68]A. Ng. Structuring machine learning projects. *deeplearning.ai*.
- [69]S. Ruder. An overview of multi-task learning in deep neural networks. *arXiv preprint arXiv:1706.05098*, 2018.
- [70]N. Srivastava, G. E Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov. Dropout: a simple way to prevent neural networks from overfitting. *Journal of machine learning research*, 15(1):1929--1958, 2014.
- [71]T. Tieleman and G. Hinton. Lecture 6.5-RMSProp: Divide the gradient by a

---

running average of its recent magnitude. COURSERA: Neural networks for machine learning, 4(2):26--31, 2012.

[72] G. Xavier and Y. Bengio. Understanding the difficulty of training deep feedforward neural networks. In proceedings of the International Conference on Artificial Intelligence and Statistics, pages 249--256, 2010.

[73] 余强毅, 吴文斌, 唐华俊, 等. 基于农户行为的农作物空间格局变化模拟模型架构[J]. 中国农业科学, 2013, 46(15): 3266-3276.

[74] 陈凯, 刘凯, 柳林, 等. 基于随机森林的元胞自动机城市扩展模拟: 以佛山市为例[J]. 地理科学进展, 2015. 34(8): 937-946.

[75] 陈海, 梁小英, 高海东, 等. Multi-Agent System 模型在土地利用/覆盖变化中的研究进展[J]. 自然资源学报, 2008. 23 (2): 345-352.

[76] 余强毅, 吴文斌, 唐华俊, 等. 复杂系统理论与 Agent 模型在土地变化科学中的研究进展[J]. 地理学报, 2011, 66(11): 1518-1530.

[77] 陈海, 梁小英, 王国义, 等. 基于过程的农户土地利用行为模型的设计与模拟研究[J]. 自然资源学报, 2014, 29(6): 1076-1089.

[78] 余强毅, 吴文斌, 杨鹏, 等. Agent 农业土地变化模型研究进展[J]. 生态学报, 2013, 33(6): 1690-1700.

[79] 王艳妮, 陈海, 宋世雄, 等. 基于 CR-BDI 模型的农户作物种植行为模拟: 以陕西省米脂县姜兴庄为例[J]. 地理科学进展, 2016. 35(10): 1258-1268.

[80] 李少英, 刘小平, 黎夏, 等. 土地利用变化模拟模型及应用研究进展[J]. 遥感学报, 2017, 21(3): 329-340.

[81] 张延伟, 裴颖, 葛全胜. 基于 BDI 决策的居住空间宜居性分析: 以大连沙河口区为例[J]. 地理研究, 2016, 35(12): 2227-2237.

[82] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(06): 1229-1251.

[83] 侯越. 基于改进 T-S 模糊神经网络的交通流量预测[J]. 计算机科学与探索, 2014, (1): 121-126.

[84] 党宇, 张继贤, 邓喀中, 等. 基于深度学习 AlexNet 的遥感影像地表覆盖分类评价研究[J]. 地球信息科学学报, 2017. (11): 1530-1537.

[85] 郭宁宁, 盛业华, 黄宝群, 等. 基于人工神经网络的多特征因子路网匹配算

---

法[J]. 地球信息科学学报, 2016, (09): 1153-1159.

[86] Hinton G, Deng L, Yu D, et al. Deep neural networks for acoustic modeling in speech recognition: the shared views of four research groups. *IEEE Signal Processing Magazine*, 2012, 29(6): 82-97.

[87] Goodfellow I, Bengio Y, Courville A. *Deep Learning*[M]. Cambridge, UK: MIT Press, 2016.

[88] Srivastava N, Hinton G, Krizhevsky A, et al.. Dropout: A simple way to prevent neural networks from overfitting[J]. *The Journal of Machine Learning Research*, 2014, 15(1): 1929-1958.

[89] 王瑞波, 李济洪, 李国臣, 等. 基于 Dropout 正则化的汉语框架语义角色识别[J]. *中文信息学报*, 2017, 31(1): 147-154.

---

## 致谢

时光如梭，在西北大学的三年研究生学习生活即将画上一个句号，临近毕业之际，回首往昔，那些奋斗拼搏的日子中，有艰辛，也有快乐，有付出，也有收获，不仅学习到了很多知识技能，更多的是学会了成长，这些都让我难忘，更是让我不甚感激。

首先我要诚挚地感谢我的导师梁小英副教授，能成为梁老师的学生，我感到无比幸运。梁老师性格温和谦逊，淡定从容，不仅传道授业，还耐心的为我们解惑。每当我不论在学习还是生活上感到困惑的时候，老师总是细心地对我进行开导。这篇论文也是在梁老师的悉心指导下完成的，从论文的选题、写作到最后的修改，老师都在百忙之中抽出时间亲自修改，这着实让我感动。

2017 年和 2018 年暑假，在梁老师的带领下两次去米脂县进行农户调查的情景仿佛就在昨天。作为 2017 年暑期调研的主要负责人之一，这个调研过程中，不仅教会我如何脚踏实地地做研究，也教会我如何带领一个团队更好地完成任务、如何顾全大局的同时兼顾细节、如何为人处世。调研过程中老师教会我如何扎实地进行学术研究，还为我提供了更加全面和新颖的思考方式，这对我后来的学术研究带来了极大的帮助。尤其是在调研过程中，我脚部受到细菌感染，老师对我体贴细心的关怀和照顾，让我感到无比温暖。

其次，在这三年的学习生涯中，我还要特别感谢陈海教授。陈老师平日里治学态度严谨，在我平时不仔细的时候，老师总是细心、耐心地批评指正，这也让我感受到了老师的责任心和用心良苦，也让我明白了对待学术和科研一定要端正态度，认真负责。

感谢课题组的毛南赵师兄；史琴琴师姐；赵岩师弟以及商舒涵师妹在数据收集和整理过程中给予的帮助。

感谢同窗刘迪、马胜和王嘉妮。谢谢你们的陪伴与支持。感谢舍友林依硕的鼓励，感谢挚友李新尧、陈浩等一路相伴、同心共济。感谢城市与环境学院的老师们在我的学习和生活中对我的无私帮助，感谢西北大学为我们提供了优良的校风，自由开放的学术平台，同时也教会了我何为公诚勤朴。

最后，感谢我的家人，谢谢你们对我学业的理解支持，谢谢你们的包容和陪伴。毕业，意味着一段旅程的结束，也象征着人生新篇章的开启。

---

## 攻读硕士学位期间取得的科研成果

### 1. 发表学术论文

[1] 梁小英. 段宁. 刘康. 等. 土地利用功能变化与农户响应研究进展.[J]. 干旱区地理. 2019(2).

[2] 毛南赵. 梁小英. 段宁.等. 基于 ODD 框架的农户有限理性决策模型的构建及模拟.[J]. 中国农业资源与区划. 2018, 39(5): 164-171,218 (核心)

### 2. 参与科研项目及科研获奖

[1]国家自然科学基金项目，生态脆弱区土地利用功能变化及农户响应研究——以陕西省米脂县为例（项目号， 41671086）， 2017-2020，主要负责模型构建与模拟（主持人：梁小英）；

[2]国家自然科学基金项目，生态脆弱区土地集约利用模拟研究——以陕西省米脂县为例（项目号， 41271103）， 2013-2016，已结题，主要负责野外调研等工作（主持人：陈海）；